

TĂNG CƯỜNG KHẢ NĂNG CHUYỂN KIỂU CHỮ ĐA NGÔN NGỮ TRONG BÀI TOÁN ONE-SHOT BẰNG MÔ HÌNH KHUẾCH TÁN

Sinh viên thực hiện: **Trần Đình Khánh Đăng**

Giảng viên hướng dẫn: **TS. Dương Việt Hằng**

Lớp khoá học: **KHMT2022.1**

Khoa: **Khoa học máy tính**

Mục lục

1. Giới thiệu
2. Phương pháp đề xuất
3. Thực nghiệm và kết quả
4. Kết luận

Mục lục

1. Giới thiệu

2. Phương pháp đề xuất

3. Thực nghiệm và kết quả

4. Kết luận

Thách thức của thiết kế truyền thống

Quy trình thiết kế font truyền thống gặp 3 rào cản lớn:

1. Chi phí:

- Quy trình vẽ tay tốn kém nhân lực và thời gian.
- Hiệu suất thấp do tính chất lặp lại thủ công.

2. Quy mô:

- Latin: ~52 ký tự.
- **CJK (Hán/Nôm)**: Hàng vạn ký tự (> 50.000 ký tự).

→ **Bất khả thi nếu làm tay hoàn toàn.**

3. Rào cản Đa ngôn ngữ:

- Các ngôn ngữ **Low-resource** hoặc có **dấu phức tạp** (như Tiếng Việt) **thường xuyên bị thiếu font đồng bộ.**

→ Gây khó khăn lớn cho việc **Bản địa hoá thương hiệu.**

Giải pháp: One-shot Font Generation

Cơ chế **One-shot**: Tách biệt phong cách từ **1 mẫu ảnh** → Chuyển giao (Transfer) sang **bất kỳ ký tự nào**.

+

→

Nội dung (Content)

1 Mẫu Style (Reference)

Kết quả (Generated)

→ Giải pháp tối ưu cho bài toán Chi phí, Quy mô và Đa ngôn ngữ.

Mục tiêu & Đóng góp

Mục tiêu: Xây dựng giải pháp **Cross-Lingual (Đa ngôn ngữ)** tổng quát.

→ **Phạm vi (Scope)**: Tập trung vào cặp **Latin - Hán tự**. (Lý do: Đây là cặp có cấu trúc khác biệt lớn nhất → Bài toán khó nhất).

Đóng góp chính:

1. Xây dựng pipeline dựa trên **Diffusion Model**.
2. Đề xuất mô-đun **CL-SCR** để xử lý khác biệt cấu trúc.

Khoảng cách hình thái học (Morphological Gap)

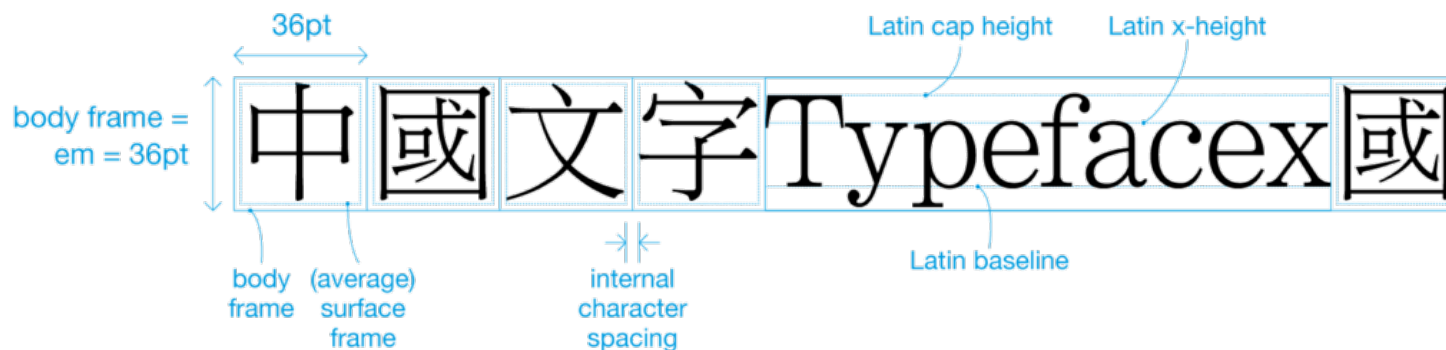
Tại sao Latin - Hán tự là thách thức lớn nhất?

1. Latin (Hệ chữ cái):

- Cấu trúc tuyến tính (Linear), ít nét.
- **Vấn đề:** Quá ít thông tin để suy diễn.

2. Hán tự (Hệ tượng hình):

- Cấu trúc khối vuông (Block), dày đặc.
- **Vấn đề:** Dễ bị biến dạng cấu trúc.



→ Rào cản lớn nhất trong việc bảo toàn cấu trúc khi chuyển đổi phong cách.

Mục lục

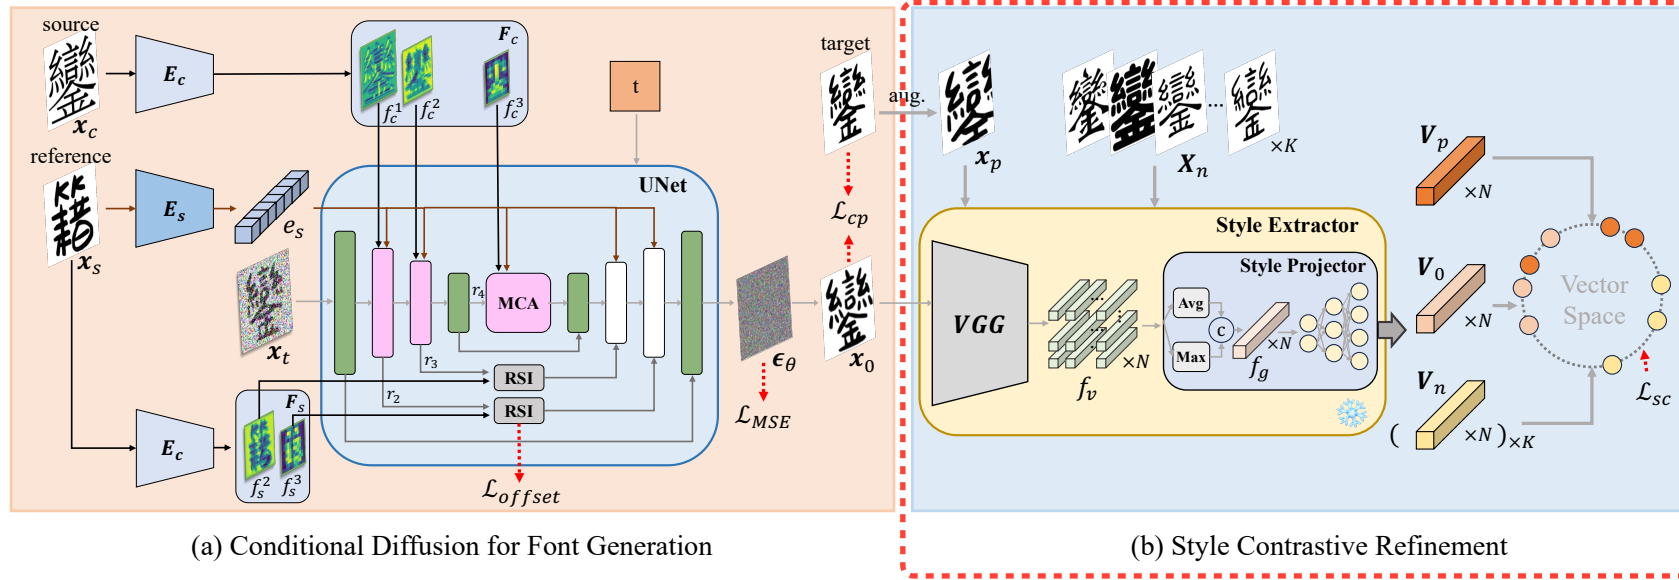
1. Giới thiệu

2. Phương pháp đề xuất

3. Thực nghiệm và kết quả

4. Kết luận

Kiến trúc đề xuất



(a) Conditional Diffusion for Font Generation

(b) Style Contrastive Refinement

Khu vực cải tiến

Giai đoạn 1 (Nền tảng FontDiffuser):

- **MCA**: Tổng hợp đặc trưng đa tỷ lệ.
- **RSI**: Xử lý biến dạng hình học.
- → **Mục tiêu**: Đảm bảo tái tạo đúng **cấu trúc chữ**.

Giai đoạn 2 (Trong khung đỏ):

- Thay thế mô-đun SCR gốc bằng kiến trúc **CL-SCR** đề xuất.
- → Nâng cấp khả năng học **Cross-Lingual**.

Động lực & Ý tưởng

Vấn đề của Giai đoạn 1:

- Giai đoạn 1 chỉ tập trung tối ưu hoá **điểm ảnh** (Pixel-wise).
- → Học tốt cấu trúc nhưng yếu về **biểu diễn phong cách trừu tượng**. Khi chuyển sang hệ chữ khác, mô hình bị “mất phương hướng” vì không còn điểm ảnh tương đồng để so sánh.

Trực giác cho Giai đoạn 2 (Cross-Lingual Bridge):

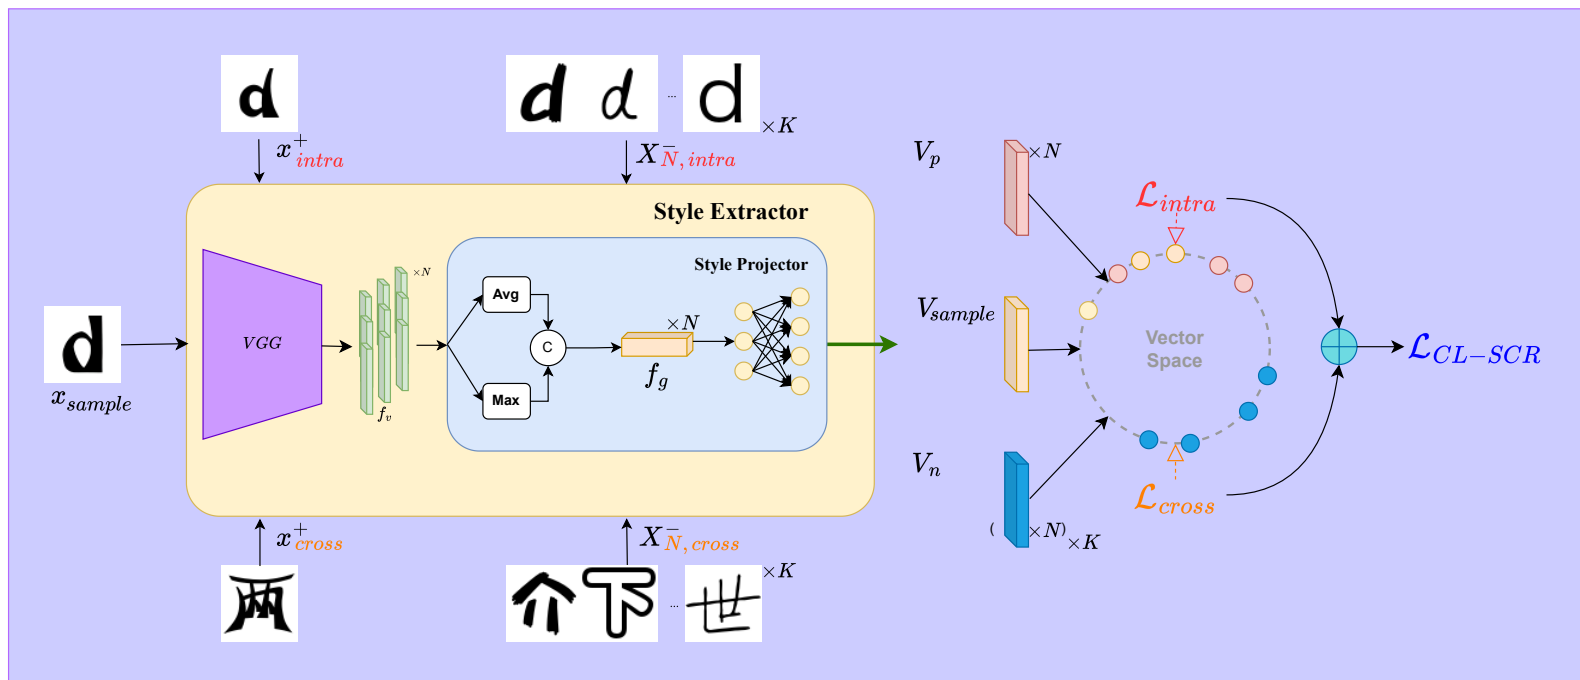
- Cần một cơ chế **tách biệt phong cách** khỏi nội dung.
- Tận dụng các **nét tương đồng** (stroke-level) giữa Latin và Hán tự thông qua cơ chế **Học tương phản (Contrastive Learning)**.
- → Dùng CL-SCR để “ép” mô hình tìm ra mẫu số chung về phong cách giữa hai ngôn ngữ.

Giải pháp CL-SCR: Áp dụng cơ chế Contrastive Learning:

- **Intra-domain:** Giữ bản sắc ngôn ngữ nguồn.
- **Cross-domain:** Tìm điểm chung giữa hai hệ chữ.

Kiến trúc mô-đun CL-SCR

Cơ chế giám sát luồng đôi (Dual-stream Supervision):



Hình 3.7: Kiến trúc mạng CL-SCR với hai luồng giám sát Intra và Cross.

Công thức hàm Loss (CL-SCR)

Dựa trên nguyên lý **InfoNCE** (Cơ chế Kéo - Đẩy):

1. Intra-Lingual (L_{intra})

$$L_{\text{intra}} = -\log \frac{\exp(q \cdot k^+)}{\exp(q \cdot k^+) + \sum \exp(q \cdot k^-)}$$

→ **Mục tiêu:** Đảm bảo tính nhất quán nội bộ.

2. Cross-Lingual (L_{cross})

$$L_{\text{cross}} = -\log \frac{\exp(q \cdot k_{\text{cross}}^+)}{\exp(q \cdot k_{\text{cross}}^+) + \sum \exp(q \cdot k_{\text{cross}}^-)}$$

→ **Mục tiêu:** Kéo ảnh sinh về phía phong cách đích (Target).

Tổng hợp Loss:

$$L_{\text{CL-SCR}} = \alpha \cdot L_{\text{intra}} + \beta \cdot L_{\text{cross}}$$

(Trong đó $\beta > \alpha$ để ưu tiên học chuyển đổi đa ngữ)

Hàm mục tiêu tổng quát

Mô hình tối ưu hoá đồng thời 4 thành phần:

$$L_{\text{total}} = \underbrace{L_{\text{MSE}}}_{\text{Tái tạo ảnh}} + \lambda_{\text{cp}} \underbrace{L_{\text{cp}}}_{\text{Nội dung}} + \lambda_{\text{offset}} \underbrace{L_{\text{offset}}}_{\text{Cấu trúc}} + \lambda_3 \underbrace{L_{\text{CL-SCR}}}_{\text{Phong cách (Đề xuất)}}$$

- L_{MSE} & L_{offset} : Giữ vai trò bảo toàn khung xương (Giai đoạn 1).
- $L_{\text{CL-SCR}}$: Đóng vai trò then chốt trong việc chuyển giao phong cách (Giai đoạn 2).

Mục lục

1. Giới thiệu
2. Phương pháp đề xuất
- 3. Thực nghiệm và kết quả**
4. Kết luận

Chiến lược Huấn luyện

Thiết lập: GPU Tesla P100 (16GB) \diamond Batch size: 4 \diamond **Inference:** DPM-Solver++ (20 bước).
(Mô-đun CL-SCR được tiền huấn luyện (pre-train) độc lập trước khi đưa vào Giai đoạn 2).

Giai đoạn 1: Khởi tạo

- **Mục tiêu:** Học tái tạo cấu trúc chữ (Skeleton).
- **Loss:** $L_{\text{MSE}} + \lambda_{\text{cp}} L_{\text{cp}} + \lambda_{\text{offset}} L_{\text{offset}}$.
- **Quy mô:** 400.000 bước (Steps).
- **Learning Rate:** 1×10^{-4} .

→ **Kết quả:** Học cấu trúc nội dung và phong cách cơ bản.

Giai đoạn 2: Tinh chỉnh

- **Mục tiêu:** Tách biệt và chuyển giao Style (Cross-Lingual).
- **Loss:** Thêm hàm **CL-SCR** (Contrastive Loss).
- **Quy mô:** 30.000 bước.
- **Learning Rate:** Giảm xuống 1×10^{-5} .
- **Kỹ thuật:** Áp dụng **Data Augmentation** (Random Crop) để chống học vẹt.

→ **Kết quả:** Phong cách sắc nét, chuẩn xác.

Dữ liệu & Kịch bản đánh giá

Cơ sở thực nghiệm của khoá luận:

1. Bộ dữ liệu:

- **Nguồn:** 818 font song ngữ (FTransGAN).
- **Cấu trúc:** Ghép cặp Latin (~52 ký tự) và Hán tự (~800 ký tự).

→ Đảm bảo sự nhất quán phong cách (Ground-truth).

2. Kịch bản:

a. SFUC (Font đã biết):

- Sinh ký tự mới từ font đã train.
- **Mục tiêu:** Kiểm tra khả năng “học thuộc”.

b. UFSC (Font chưa biết - Quan trọng):

- Sinh ký tự từ font **mới hoàn toàn**.
- **Mục tiêu:** Đánh giá khả năng **One-shot Generalization**.

Các thước đo đánh giá

Để đảm bảo tính khách quan, khoá luận sử dụng hệ thống đo lường đa chiều:

1. Định lượng:

- **FID (Quan trọng nhất):** Đo khoảng cách phân bố giữa ảnh sinh và ảnh thật.
→ **FID càng thấp** → **Ảnh càng chân thực.**
- **L1 / SSIM:** Đo độ chính xác về điểm ảnh (Pixel) và cấu trúc (Structure).
- **LPIPS:** Đo độ tương đồng theo nhận thức của mắt người.

2. Định tính:

- **Kiểm tra trực quan:** So sánh trực quan các chi tiết nét.
- **Khảo sát người dùng:** Khảo sát mù trên người dùng để đánh giá độ hài lòng.


Kết quả định lượng

	Model	SFUC				UFSC			
		L1 ↓	SSIM ↑	LPIPS ↓	FID ↓	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
L → C	DG-Font	0.2773	0.2702	0.4023	106.3833	0.2797	0.2654	0.3649	54.0974
	CF-Font	0.2659	0.2740	0.3979	91.2134	0.2638	0.2716	0.3615	51.3925
	DFS	0.2131	0.3558	0.3812	45.4212	0.2008	0.3048	0.3876	62.7206
	FTransGAN	0.1844	0.3900	0.3548	40.4561	<u>0.2089</u>	<u>0.3109</u>	0.3329	42.1053
	FontDiffuser (Baseline)	0.1976	0.3775	<u>0.2968</u>	<u>14.6871</u>	0.2283	0.2946	<u>0.3184</u>	<u>29.0999</u>
	Ours	<u>0.1939</u>	<u>0.3890</u>	0.2911	11.7691	0.2214	0.3197	0.2954	13.5508
C → L	DG-Font	0.1462	0.5542	0.2821	74.1655	0.1397	0.5624	0.2751	89.8197
	CF-Font	0.1402	0.5621	0.2790	67.1241	0.1317	0.5756	0.2726	84.3787
	DFS	0.1083	<u>0.6140</u>	0.2585	40.4042	<u>0.1139</u>	<u>0.5819</u>	0.2907	75.2760
	FTransGAN	0.1381	0.5291	0.2851	55.5859	0.1456	0.4949	0.3023	88.4450
	FontDiffuser (Baseline)	<u>0.1223</u>	0.6107	<u>0.2270</u>	<u>21.2234</u>	0.1370	0.5731	<u>0.2476</u>	<u>59.5788</u>
	Ours	0.1083	0.6406	0.2019	14.7298	0.1090	0.6377	0.1985	41.1152

Kết quả định tính

Source	c	d	e	f	g	毛	毫	民	气	水
Reference	衣	牛	士	生	至	Z	D	W	B	J
DG-Font	衣	牛	士	生	至	毛	毫	民	气	水
CF-Font	衣	牛	士	生	至	毛	毫	民	气	水
DFS	衣	牛	士	生	至	毛	毫	民	气	水
FTransGAN	衣	牛	士	生	至	毛	毫	民	气	水
FontDiffuser	衣	牛	士	生	至	毛	毫	民	气	水
(Baseline)	衣	牛	士	生	至	毛	毫	民	气	水
Ours	衣	牛	士	生	至	毛	毫	民	气	水
Target	衣	牛	士	生	至	毛	毫	民	气	水

Đánh giá người dùng



Hiệu quả của các mô-đun kiến trúc

	Mô-đun			SFUC				UFSC			
				L1 ↓	SSIM ↑	LPIPS ↓	FID ↓	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
M	R	CL									
U	✓	✓	✗	<u>0.1977</u>	<u>0.3809</u>	<u>0.2927</u>	10.9069	<u>0.2266</u>	<u>0.3072</u>	<u>0.3009</u>	<u>14.8680</u>
↑	✗	✗	✓	0.2679	0.2415	0.5199	161.0711	0.2966	0.1687	0.5606	180.2861
U	✓	✓	✓	0.1939	0.3890	0.2911	<u>11.7691</u>	0.2214	0.3197	0.2954	13.5508
U	✓	✓	✗	0.1076	0.6449	0.2005	14.3511	0.1070	0.6413	0.1980	<u>42.8665</u>
↑	✗	✗	✓	0.3234	0.2520	0.5469	205.2360	0.3882	0.1849	0.5951	239.9641
U	✓	✓	✓	<u>0.1083</u>	<u>0.6406</u>	<u>0.2019</u>	<u>14.7298</u>	<u>0.1090</u>	<u>0.6377</u>	<u>0.1985</u>	41.1152

Mục lục

1. Giới thiệu
2. Phương pháp đề xuất
3. Thực nghiệm và kết quả
- 4. Kết luận**

Tổng kết đóng góp

Khoá luận đã hoàn thành các mục tiêu đề ra ban đầu:

- Xây dựng thành công Pipeline chuyển đổi phong cách **xuyên hệ chữ (Cross-Script)**, đặc biệt là cặp khó Latin - Hán tự.
- Đề xuất mô-đun **CL-SCR** với cơ chế **Contrastive Learning**, giải quyết hiệu quả vấn đề “Domain Gap” giữa các ngôn ngữ.
- Vượt trội SOTA hiện tại (FID giảm $\sim 50\%$), khắc phục triệt để lỗi “**Bóng ma**” (Ghosting) và “**Biến dạng cấu trúc**” thường gặp ở GAN.

Hạn chế & Hướng phát triển

Định hướng nghiên cứu trong tương lai:

Hạn chế:

- **Thách thức về Tốc độ:** Do bản chất khử nhiễu lặp lại (Iterative Denoising) của Diffusion, tốc độ suy diễn chậm hơn các phương pháp One-step (GAN).
- **Đánh đổi:** Chất lượng ảnh cao đổi lấy chi phí tính toán lớn.

Hướng phát triển:

- **Tăng tốc:** Áp dụng **Consistency Distillation** hoặc **Latent Consistency Models (LCM)** để giảm xuống còn 4-8 bước.
- **Mở rộng:** Ứng dụng cho **Tiếng Việt (Thư pháp)** và các ngôn ngữ Low-resource khác.
- **Ứng dụng:** Sinh font dạng **Vector (SVG)** để tích hợp trực tiếp vào phần mềm thiết kế.

Công trình khoa học

D. K. D. Tran and V. H. Duong, “CL-SCR: Decoupling Style and Structure for One-Shot Cross-Script Font Generation,” *The Journal of Supercomputing (under review)*, 2026.

Lời cảm ơn

**Xin cảm ơn Thầy Cô và Hội đồng
đã theo dõi và lắng nghe!**

Sinh viên thực hiện: **Trần Đình Khánh Đăng**

Giảng viên hướng dẫn: **TS. Dương Việt Hăng**

Lớp khoá học: **KHMT2022.1**

Khoa: **Khoa học máy tính**

Tối ưu hoá CL-SCR

Cơ sở thực nghiệm để lựa chọn các siêu tham số tốt nhất.

a. **Chế độ Hàm Loss (Loss Modes):** Tại sao phải kết hợp cả Intra và Cross?

Chế độ	FID (UFSC) ↓	
	L → C	C → L
Intra-only	15.72	41.34
Cross-only	16.26	44.78
Both	13.55	41.12

→ **Both** tận dụng sự ổn định của Intra và khả năng chuyển đổi của Cross.

b. **Trọng số Alpha (α) & Beta (β):** Tại sao ưu tiên $\beta = 0.7$?

α	β	FID (UFSC) ↓	
		L → C	C → L
0.7	0.3	14.48	45.23
0.5	0.5	15.18	43.42
0.3	0.7	13.55	41.12

→ Bài toán Cross-Lingual cần ưu tiên học các đặc trưng xuyên ngôn ngữ (β lớn).

Phân tích độ nhảy

Ảnh hưởng của Số mẫu âm & Guidance Scale

c. Số lượng mẫu âm (K): Trong hàm loss InfoNCE.

K	FID (UFSC) ↓	
	L → C	C → L
4	13.55	41.12
8	15.02	43.81
16	16.79	43.50

→ $K=4$ là điểm cân bằng tối ưu cho cả hai chiều.

d. Trọng số hướng dẫn (Scale - s): Cân bằng giữa đa dạng và chính xác.

Scale (s)	FID (UFSC) ↓	
	L → C	C → L
2.5	13.28	40.05
5.0	13.39	40.00
7.5	13.55	41.12
10.0	13.78	44.74
12.5	14.78	47.15
15.0	17.01	52.76

→ s thấp ($\in [2.5, 7.5]$) cho kết quả tốt nhất.

Phân tích độ nhảy

Đánh giá hiệu quả của chiến lược Tăng cường dữ liệu (Data Augmentation).

e. Tăng cường dữ liệu: So sánh mô hình khi dùng/ không dùng kỹ thuật tăng cường dữ liệu.

Cấu hình	FID (UFSC) ↓	
	L → C	C → L
w/o Augmentation	<u>15.77</u>	<u>43.07</u>
w/ Augmentation	13.55	41.12

→ Việc áp dụng Augmentation giúp giảm đáng kể FID, chứng tỏ mô hình học được các đặc trưng phong cách **bền vững** hơn, tránh bị Overfitting.

Chiến lược: Random Resized Crop

- **Scale (0.8 – 1.0):** Cắt ngẫu nhiên nhưng giữ lại phần lớn cấu trúc chữ.
- **Ratio (0.8 – 1.2):** Thay đổi tỷ lệ khung hình nhẹ để mô phỏng các biến thể viết tay.

→ Giúp mô-đun **CL-SCR** không bị “học vẹt” (memorize) các vị trí pixel cố định.