

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

TRẦN ĐÌNH KHÁNH ĐĂNG

KHÓA LUẬN TỐT NGHIỆP

TĂNG CƯỜNG KHẢ NĂNG CHUYỂN KIẾU
CHỮ ĐA NGÔN NGỮ TRONG BÀI TOÁN ONE-
SHOT BẰNG MÔ HÌNH KHUẾCH TÁN

Enhancing One-shot Cross-Script Font Style
Transfer using Diffusion

CỦ NHÂN NGÀNH KHOA HỌC MÁY TÍNH

TP.HỒ CHÍ MINH, 2025

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA KHOA HỌC MÁY TÍNH

TRẦN ĐÌNH KHÁNH ĐĂNG - 22520195

KHÓA LUẬN TỐT NGHIỆP

TĂNG CƯỜNG KHẢ NĂNG CHUYỂN KIẾU
CHỮ ĐA NGÔN NGỮ TRONG BÀI TOÁN ONE-
SHOT BẰNG MÔ HÌNH KHUẾCH TÁN

Enhancing One-shot Cross-Script Font Style
Transfer using Diffusion

CỦ NHÂN NGÀNH KHOA HỌC MÁY TÍNH

GIẢNG VIÊN HƯỚNG DẪN:

TS. Dương Việt Hằng

TP.HỒ CHÍ MINH, 2025

LỜI CAM ĐOAN

Em xin cam đoan: Khoá luận tốt nghiệp với đề tài “Tăng cường khả năng chuyển kiều chữ đa ngôn ngữ trong bài toán one-shot bằng mô hình khuếch tán” trong báo cáo này là do em thực hiện dưới sự hướng dẫn của Tiến sĩ Dương Việt Hằng. Nhũng gì em viết ra hoàn toàn trung thực, chính xác và không có sự sao chép từ các tài liệu, không sử dụng kết quả của người khác mà không trích dẫn cụ thể. Đây là công trình nghiên cứu cá nhân em tự phát triển, không sao chép mã nguồn của người khác. Nếu vi phạm nhũng điều trên, em xin chấp nhận tất cả nhũng truy cứu về trách nhiệm theo quy định của Trường Đại học Công nghệ Thông tin — ĐHQGHCN.

Hồ Chí Minh, ngày 10 tháng 12 năm 2025

Sinh viên

Trần Đình Khánh Đăng

LỜI CẢM ƠN

Lời đầu tiên, cho phép em bày tỏ lòng biết ơn sâu sắc đến Quý thầy/cô ở Khoa Khoa học máy tính và Trường Đại học Công nghệ Thông tin — ĐHQGHC. Đây là nơi em đã có cơ hội tiếp cận với những tri thức mới mẻ, được học hỏi từ các thầy cô xuất sắc và kết nối với những người bạn, anh chị em đầy năng động và tài năng.

Em cũng xin gửi lời cảm ơn chân thành nhất đến cô Dương Việt Hằng, người đã luôn là nguồn cảm hứng và sự hướng dẫn quý báu trong suốt thời gian em học tập tại trường. Sự tận tâm và hỗ trợ nhiệt tình của cô đã tiếp thêm động lực để em vượt qua những thử thách trong hành trình nghiên cứu và hoàn thiện khóa luận tốt nghiệp.

Ngoài ra, em xin gửi lời cảm ơn đến gia đình, bạn bè và những người đã luôn giúp đỡ, động viên, đồng hành cùng em suốt chặng đường học tập ở trường và khoảng thời gian thực hiện khóa luận.

Kính chúc tất cả mọi người luôn vui vẻ, hạnh phúc và gặt hái được nhiều thành công trong cuộc sống.

Một lần nữa, xin chân thành cảm ơn tất cả những tấm lòng đã đồng hành cùng em suốt chặng đường qua!

TÓM TẮT

Tóm tắt: Bài toán sinh phông chữ tự động là một nhánh quan trọng trong thị giác máy tính, nhằm tạo ra các ký tự mới với phong cách (style) đồng nhất từ một số lượng mẫu tối thiểu. FontDiffuser là một phương pháp tiên tiến dựa trên mô hình khuếch tán (Diffusion Model), cho phép sinh ảnh ký tự chất lượng cao và duy trì tính nhất quán về phong cách tốt hơn so với các mô hình GAN truyền thống.

Trong nghiên cứu này, em kế thừa pipeline huấn luyện hai giai đoạn của FontDiffuser (trong đó giai đoạn 2 sử dụng Style Contrastive Regularization – SCR) và **đề xuất mở rộng SCR sang bài toán cross-lingual**. Cụ thể, em thiết kế **cross-lingual SCR loss** nhằm học biểu diễn phong cách bắt biến theo ngôn ngữ, đồng thời bổ sung cơ chế điều chỉnh trọng số giữa **intra-loss** và **cross-loss** để tối ưu chất lượng sinh font trong bối cảnh dữ liệu đa ngôn ngữ.

Hệ thống được bổ sung cơ chế checkpoint giúp tiếp tục huấn luyện từ trạng thái trước đó, hỗ trợ tập dữ liệu lớn và rút ngắn thời gian huấn luyện. Kết quả thực nghiệm cho thấy phương pháp đề xuất cải thiện đáng kể độ trung thành phong cách (style consistency) và chất lượng trực quan của ký tự sinh ra, đồng thời tăng khả năng tổng quát hóa khi áp dụng phong cách từ hệ chữ này sang hệ chữ khác.

Từ khoá: *FontDiffuser, Style Contrastive Regularization, Cross-lingual SCR, Diffusion Model, Font Generation*

MỤC LỤC

Lời cam đoan	i
Lời cảm ơn	ii
Tóm tắt	iii
Mục lục	iv
Danh mục hình ảnh	vii
Danh mục bảng	viii
Danh mục giải thuật	ix
Chương 1 . Giới Thiệu	1
1.1. Giới thiệu bài toán	1
1.2. Mô tả bài toán	2
1.2.1. Định nghĩa đầu vào (Input)	2
1.2.2. Định nghĩa đầu ra (Output)	3
1.2.3. Mục tiêu toán học	3
1.3. Mục tiêu của đề tài	4
1.4. Đối tượng và phạm vi nghiên cứu	4
1.4.1. Đối tượng nghiên cứu	4
1.4.2. Phạm vi nghiên cứu	5
1.5. Cấu trúc của khoá luận	5
Chương 2 . Cơ sở Lý thuyết và Tổng quan Tài liệu	7
2.1. Tổng quan về các phương pháp Sinh phông chữ	7
2.1.1. Các phương pháp dựa trên GAN[1] (GAN-based Approaches)	7
2.1.2. Mô hình khuếch tán[2] (Diffusion Models)	12

2.2. Lý thuyết về Biểu diễn Phong cách (Style Representation)	15
2.2.1. Neural Style Transfer truyền thống	15
2.2.2. Học tương phản (Contrastive Learning)	16
2.3. Thách thức trong bài toán Cross-Lingual: Chuyển đổi Hai chiều giữa Latin và Hán tự	16
2.3.1. Vấn đề Chênh lệch Mật độ Thông tin (Information Density Gap) .	16
2.3.2. Khoảng cách Hình thái học (Morphological Gap)	17
Chương 3 . Phương Pháp Đề Xuất	18
3.1. Giới thiệu chương	18
3.2. Kiến trúc nền tảng FontDiffuser	18
3.2.1. Giai đoạn 1: Tái tạo cấu trúc (Reconstruction Phase)	20
3.2.2. Giai đoạn 2: Tinh chỉnh phong cách (Style Refinement Phase) .	22
3.3. Phân tích Module Style Contrastive Refinement (SCR)	23
3.3.1. Động lực và Kiến trúc	23
3.3.2. Kiến trúc Khai thác Phong cách (Style Extractor Architecture) .	23
3.3.3. Cơ chế Học Tương phản và Hàm Mát mát (Contrastive Learning and Loss Function)	25
3.4. Kết hợp vào Mục tiêu Huấn luyện (Training Objective)	26
3.5. Cải tiến đề xuất: Cross-Lingual Style Contrastive Refinement (CL-SCR)...	
3.5.1. Hạn chế của SCR trong bối cảnh đa ngôn ngữ	27
3.5.2. Thiết kế module CL-SCR	28
3.6. Đề xuất thuật toán tính CL-SCR	30
Chương 4 . Thực Nghiệm và Đánh Giá Kết Quả	32

4.1. Bộ dữ liệu (Datasets)	32
4.1.1. Cấu trúc	32
4.1.2. Tiền xử lý và Chuẩn hoá	33
4.2. Thiết lập Thực nghiệm	33
4.2.1. Cấu hình Huấn luyện (Implementation Details)	33
4.2.2. Kịch bản Đánh giá (Evaluation Scenarios)	35
4.3. Các thước đo đánh giá (Evaluation Metrics)	35
4.3.1. Chỉ số Định lượng (Quantitative Metrics)	35
4.3.2. Đánh giá Định tính (Qualitative Study)	37
4.4. Kết quả Thực nghiệm và Thảo luận	38
4.4.1. So sánh Định lượng (Quantitative Results)	40
4.4.2. So sánh Định tính (Qualitative Analysis)	45
4.4.3. Đánh giá Cảm nhận Người dùng (User Study)	45
4.5. Nghiên cứu Bóc tách (Ablation Study)	45
4.5.1. Ảnh hưởng của các mô-đun trong FontDiffuser	45
4.5.2. Ảnh hưởng của Tăng cường dữ liệu (Data Augmentation)	48
4.5.3. Ảnh hưởng của Chế độ hàm loss	51
4.5.4. Ảnh hưởng của số lượng mẫu âm	53
Chương 5 . Kết Luận và Hướng Phát Triển	57
5.1. Kết quả đạt được	57
5.2. Các định hướng phát triển	58
Tài liệu tham khảo	59
Phụ lục	63

DANH MỤC HÌNH ẢNH

Hình 2.1	Kiến trúc mạng DG-Font. Mô-đun FDSC đóng vai trò nòng cốt trong việc học biến dạng hình học giữa các ký tự.	8
Hình 2.2	Minh họa cơ chế Content Fusion: Các đặc trưng từ tập font cơ sở (Source) được tổ hợp tuyển tính dựa trên bộ trọng số dự đoán (Weights) để xấp xỉ cấu trúc hình học của font mục tiêu.	9
Hình 2.3	Kiến trúc mạng DFS với thành phần cốt lõi là Ma trận Tương đồng (SM) giúp điều hướng dòng chảy thông tin phong cách.	11
Hình 2.4	Tổng quan kiến trúc FTransGAN.	12
Hình 2.5	Quá trình Khuếch tán xuôi	13
Hình 2.6	Quá trình Khuếch tán ngược	14
Hình 3.1	Mô hình tổng thể của FontDiffuser gồm 2 giai đoạn: Tái tạo cấu trúc (Trái) và Tinh chỉnh phong cách (Phải)	19
Hình 3.2	Ví dụ về ảnh nội dung	19
Hình 3.3	Ví dụ về ảnh phong cách	19
Hình 3.4	Ví dụ về ảnh đầu ra	20
Hình 3.5	Khối MCA (Multi-scale Content Aggregation)	21
Hình 3.6	Đặc trưng Content ở các khối khác nhau	21
Hình 3.7	Minh họa mô-đun SCR	24
Hình 4.1	Ví dụ ba loại độ phức tạp	40

DANH MỤC BẢNG

Bảng 4.1	Bảng phân loại các kịch bản dựa trên độ phức tạp của ký tự	39
Bảng 4.2	Kết quả Định lượng cho Latin → Hán tự (e2c) trên SFUC. Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).	40
Bảng 4.3	Kết quả Định lượng cho Latin → Hán tự (e2c) trên UFSC. Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).	41
Bảng 4.4	Kết quả Định lượng cho Hán tự → Latin (c2e) trên SFUC. Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).	42
Bảng 4.5	Kết quả Định lượng cho Hán tự → Latin (c2e) trên UFSC. Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).	43
Bảng 4.6	Phân tích ảnh hưởng của các thành phần M, R, S và CL đối với hiệu năng mô hình trên tác vụ Latin → Hán tự.	46
Bảng 4.7	Phân tích ảnh hưởng của các thành phần M, R, S và CL đối với hiệu năng mô hình trên tác vụ Hán tự → Latin.	46
Bảng 4.8	So sánh kết quả sinh ảnh định tính giữa các mô-đun khác nhau khác nhau trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (e2c và c2e).	47
Bảng 4.9	Phân tích ảnh hưởng của tăng cường dữ liệu đối với hiệu năng mô hình trên tác vụ Latin → Hán tự (e2c).	48
Bảng 4.10	Phân tích ảnh hưởng của tăng cường dữ liệu đối với hiệu năng mô hình trên tác vụ Hán tự → Latin (c2e).	49
Bảng 4.11	So sánh kết quả sinh ảnh định tính giữa mô hình có và không có áp dụng Tăng cường dữ liệu trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (e2c và c2e).	50
Bảng 4.12	Phân tích ảnh hưởng của các chế độ loss đối với hiệu năng mô hình trên tác vụ Latin → Hán tự (e2c).	51
Bảng 4.13	Phân tích ảnh hưởng của các chế độ loss đối với hiệu năng mô hình trên tác vụ Hán tự → Latin (c2e).	51
Bảng 4.14	So sánh kết quả sinh ảnh định tính giữa các chế độ mất mát khác nhau trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (e2c và c2e). .53	53
Bảng 4.15	Phân tích ảnh hưởng của số lượng mẫu âm đối với hiệu năng mô hình trên tác vụ Latin → Hán tự (e2c).	54
Bảng 4.16	Phân tích ảnh hưởng của số lượng mẫu âm đối với hiệu năng mô hình trên tác vụ Hán tự → Latin (c2e).	54
Bảng 4.17	So sánh kết quả sinh ảnh định tính giữa các số lượng mẫu âm khác nhau trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (e2c và c2e). .55	55

DANH MỤC GIẢI THUẬT

Thuật toán 3.1 Thuật toán tính hàm mất mát CL-SCR 30

Chương 1

Giới Thiệu

1.1. Giới thiệu bài toán

Thiết kế phông chữ (Typeface design) từ lâu đã được xem là một loại hình nghệ thuật đòi hỏi sự kết hợp tinh tế giữa thẩm mĩ và kỹ thuật. Để tạo ra một bộ phông chữ hoàn chỉnh, các nhà thiết kế (typographers) phải vẽ thủ công hàng nghìn ký tự (glyphs) nhằm đảm bảo sự nhất quán về phong cách (style) như độ dày nét, hình dáng chân chữ (serif), và độ cong. Thách thức này càng trở nên lớn hơn đối với các hệ chữ tượng hình phức tạp như CJK (Chinese, Japanese, Korean), nơi số lượng ký tự có thể lên tới hàng chục nghìn. Do đó, các phương pháp truyền thống dựa trên nội suy (interpolation) hoặc vector hóa thủ công thường tốn kém nhiều chi phí, thời gian và khó mở rộng quy mô.

Trong bối cảnh đó, bài toán Sinh phông chữ tự động (Automatic Font Generation) đã trở thành một hướng nghiên cứu mũi nhọn trong lĩnh vực Thị giác máy tính (Computer Vision) và Học sâu (Deep Learning). Sự chuyển dịch từ các mô hình Generative Adversarial Networks (GANs)^[1] sang Denoising Diffusion Probabilistic Models (DDPMs)^[2,3] gần đây đã tạo ra bước đột phá về chất lượng ảnh sinh. Các mô hình Diffusion, điển hình như FontDiffuser^[4], đã chứng minh khả năng vượt trội trong việc tái tạo các chi tiết nét chữ phức tạp và duy trì cấu trúc tinh học của ký tự mà không gặp phải các vấn đề về mất ổn định khi huấn luyện (mode collapse) thường thấy ở GAN^[1].

Tuy nhiên, phần lớn các nghiên cứu hiện tại chỉ tập trung vào bài toán đơn ngôn ngữ (intra-lingual), tức là sinh chữ cái Latin từ mẫu Latin, hoặc sinh chữ Hán từ mẫu Hán^[5–10]. Một thách thức lớn hơn và vẫn còn nhiều “khoảng trống” nghiên cứu là bài toán sinh phông chữ đa ngôn ngữ (cross-lingual font generation).

Vấn đề cốt lõi của bài toán đa ngôn ngữ nằm ở “khoảng cách miền” (domain gap) giữa các hệ chữ viết. Ví dụ, việc chuyển đổi phong cách từ một chữ Hán (với cấu trúc nét phức tạp, ô vuông) sang chữ cái Latin (cấu trúc đơn giản, tuyến tính) đòi hỏi mô hình phải có khả năng:

- Tách biệt hoàn toàn (Disentanglement) giữa nội dung (content) và phong cách (style).
- Học được các đặc trưng phong cách bất biến (invariant style features) – những đặc điểm thẩm mỹ trừu tượng không phụ thuộc vào cấu trúc hình học của ngôn ngữ gốc.

Đây là một bài toán khó, bởi nếu không được xử lý tốt, mô hình thường có xu hướng “áp đặt” cấu trúc của ngôn ngữ nguồn lên ngôn ngữ đích, dẫn đến các ký tự bị biến dạng hoặc mất đi tính dễ đọc (legibility).


1.2. Mô tả bài toán

Phần này sẽ định nghĩa bài toán sinh phông chữ đa ngôn ngữ dưới dạng một bài toán chuyển đổi phong cách ảnh (Image-to-Image Translation)[11–14] có điều kiện.

1.2.1. Định nghĩa đầu vào (Input)

Mô hình nhận vào hai luồng thông tin chính:

- Ảnh tham chiếu nội dung (Content Image - I_c):
 - Là một hình ảnh chứa ký tự mục tiêu c (target glyph) trong một phông chữ tiêu chuẩn (ví dụ: Arial hoặc Noto Sans).
 - Mục đích: Cung cấp thông tin về cấu trúc hình học và định danh của ký tự cần sinh (ví dụ: chữ ‘A’, chữ ‘g’).
 - Trong bài toán cross-lingual, I_c thuộc hệ ngôn ngữ đích (Target Language, ví dụ: Latin).



Ví dụ về một số ảnh Content

- Ảnh tham chiếu phong cách (Style Images - I_s):
- Là tập hợp một hoặc một vài hình ảnh (k -shot) chứa các ký tự bất kỳ mang phong cách s mong muốn.
- Mục đích: Cung cấp các đặc trưng thẩm mỹ (nét xước, độ đậm nhạt, serif...).
- Trong bài toán cross-lingual, I_s thường thuộc hệ ngôn ngữ nguồn (Source Language, ví dụ: Chinese) khác với ngôn ngữ của I_c .



1.2.2. Định nghĩa đầu ra (Output)

Ảnh được sinh ra (Generated Image - I_{gen}):

- Là hình ảnh kết quả thể hiện ký tự c nhưng mang phong cách s .
- Yêu cầu: I_{gen} phải giữ được cấu trúc nội dung của I_c (đọc được là chữ gì) và mang đầy đủ đặc điểm thẩm mỹ của I_s (nhìn giống font mẫu).

1.2.3. Mục tiêu toán học

Mục tiêu là huấn luyện một hàm ánh xạ G (Generator/Diffusion Model) sao cho:

$$I_{\text{gen}} = G(I_c, I_s) \quad (1)$$

Thỏa mãn điều kiện: $\text{Content}(I_{\text{gen}}) \approx \text{Content}(I_c)$ và $\text{Style}(I_{\text{gen}}) \approx \text{Style}(I_s)$.

1.3. Mục tiêu của đề tài

Khoa luận này đề xuất mở rộng mô hình FontDiffuser để giải quyết bài toán **sinh phông chữ đa ngôn ngữ (Cross-lingual Font Generation)**, cụ thể:

- Thiết kế quy trình (pipeline) cho phép chuyển đổi phong cách hai chiều linh hoạt: trích xuất phong cách từ hệ chữ Latin để áp dụng lên Hán tự và ngược lại.
- Đề xuất cơ chế **Cross-Lingual Style Contrastive Refinement (CL-SCR)** cải tiến từ mô-đun SCR gốc, tích hợp chiến lược lấy mẫu âm đa dạng (cả nội miền và xuyên miền) nhằm buộc mô hình học được các đặc trưng phong cách bất biến, không phụ thuộc vào ngôn ngữ.
- Thực hiện huấn luyện và tinh chỉnh mô hình khuếch tán trên dữ liệu song ngữ, đồng thời đánh giá toàn diện chất lượng đầu ra dựa trên các thước đo định lượng (LPIPS, FID, SSIM, L1) và khảo sát cảm nhận người dùng.

Mục tiêu cuối cùng là tạo ra một mô hình có khả năng sinh bộ font nhất quán đa ngôn ngữ chỉ từ một mẫu tham chiếu duy nhất, mở ra tiềm năng ứng dụng trong số hóa phông chữ, thiết kế tự động và cá nhân hóa chữ viết xuyên biên giới.

1.4. Đối tượng và phạm vi nghiên cứu

Để đảm bảo tính khả thi và tập trung sâu vào giải pháp kỹ thuật, đề tài xác định rõ đối tượng và giới hạn phạm vi nghiên cứu như sau:

1.4.1. Đối tượng nghiên cứu

Mô hình lý thuyết và phát triển: Trọng tâm nghiên cứu được đặt vào **Mô hình sinh ảnh dựa trên cơ chế khuếch tán (Diffusion Models)**, lấy kiến trúc **FontDiffuser** làm nền tảng cốt lõi để cải tiến. Đề tài tập trung nghiên cứu các kỹ thuật **điều hướng phong cách (Style Guidance)** và cơ chế **học tương phản (Contrastive Learning)** trong không gian khuếch tán nhằm giải quyết bài toán chuyển đổi đa ngôn ngữ.

Mô hình đối chứng (Baseline): Để thiết lập một hệ quy chiếu đánh giá toàn diện và làm nổi bật ưu thế của phương pháp đề xuất, khóa luận thực hiện so sánh với **hai nhóm phương pháp hiện có**. Nhóm thứ nhất bao gồm **các phương pháp dựa trên GAN[1] tiên tiến** như **DG-Font[5], CF-Font[6], DFS[15]** và **FTransGAN[16]**,

nhằm chứng minh khả năng vượt trội của mô hình Khuếch tán trong việc tạo ra hình ảnh chất lượng cao và ổn định. Nhóm thứ hai là **mô hình FontDiffuser nguyên bản[4]**, được sử dụng để đối sánh trực tiếp nhằm định lượng chính xác hiệu quả đóng góp của các cải tiến kỹ thuật được đề xuất trong khóa luận (như mô-đun CL-SCR) so với thuật toán ban đầu.

Đối tượng dữ liệu: Khoa luận sử dụng **hai hệ chữ viết có đặc trưng hình thái đối lập**. Hệ chữ nguồn bao gồm các bộ phông chữ chứa ký tự Hán (theo chuẩn GB2312) với độ phức tạp cấu trúc đa dạng. Đối ứng với đó là hệ chữ đích gồm bộ 52 ký tự tiếng Anh cơ bản (26 chữ hoa và 26 chữ thường) thuộc hệ Latin.

1.4.2. Phạm vi nghiên cứu

Phạm vi về ngôn ngữ: Đề tài tập trung nghiên cứu và thực nghiệm trên bài toán **chuyển đổi phong cách hai chiều (Bidirectional Transfer)** giữa Tiếng Anh (Latin) và Tiếng Trung Quốc (Hán). Việc lựa chọn cặp ngôn ngữ này nhằm giải quyết hai thách thức hỗ trợ cho nhau. Ở hướng Latin sang Hán tự (e2c), thách thức nằm ở việc ngoại suy phong cách từ một hệ chữ đơn giản, cấu trúc thưa sang một hệ chữ phức tạp hơn rất nhiều, đòi hỏi mô hình phải học cách áp dụng phong cách lên các cấu trúc dày đặc mà không làm vỡ nét. Ngược lại, ở hướng Hán tự sang Latin (c2e), thách thức nằm ở việc trích xuất phong cách từ hệ chữ nhiều chi tiết để áp dụng lên hệ chữ đơn giản, buộc mô hình phải có khả năng tổng quát hóa cao để lọc bỏ các nhiễu cấu trúc.

Phạm vi về bài toán: Khoa luận tập trung vào **bài toán One-shot Generation**, trong đó mô hình chỉ được cung cấp một ký tự duy nhất làm ảnh tham chiếu phong cách (Style Reference) để sinh ra ký tự mục tiêu mang nội dung khác. Cụ thể, một ký tự Latin sẽ được dùng để định hình phong cách cho một Hán tự ở chiều xuôi, và một ký tự Hán sẽ được dùng để định hình phong cách cho một chữ cái Latin ở chiều ngược.

Phạm vi về dữ liệu: Sử dụng **các bộ dữ liệu phông chữ mã nguồn mở hỗ trợ đồng thời cả hai bảng mã**, ví dụ như các bộ font thuộc dự án Google Noto CJK hoặc các font nghệ thuật song ngữ. Điều này nhằm đảm bảo luôn tồn tại cặp dữ liệu đối chứng (Ground Truth) chính xác: cùng một bộ font phải chứa cả ký tự Hán và Latin tương ứng để phục vụ cho quá trình huấn luyện giám sát và đánh giá định lượng.

1.5. Cấu trúc của khoá luận

Phần còn lại của khoá luận này được trình bày như sau:

- [Chương 2](#) – Tổng Quan Lý Thuyết và Các Nghiên Cứu Liên Quan:

Trình bày các khái niệm nền tảng về bài toán sinh font chữ. Đồng thời, chương này tổng hợp và phân tích các phương pháp sinh font trước đây, bao gồm nhóm mô hình dựa trên GAN[1] (DG-Font[5], CF-Font[6], DFS[15], FTransGAN[16]) và nhóm mô hình khuếch tán[2] (FontDiffuser[4]), chỉ ra ưu nhược điểm và xu hướng phát triển.

- [Chương 3](#) – Phương Pháp Đề Xuất:

Trình bày chi tiết pipeline gốc của FontDiffuser[4], bao gồm hai giai đoạn huấn luyện (Giai đoạn 1 – Tái tạo cấu trúc, Giai đoạn 2 – Tinh chỉnh phong cách). Phân tích cơ chế hoạt động của các mô-đun chính như MCA (Multi-scale Content Aggregation), RSI (Reference-Structure Interaction) và SCR (Style Contrastive Refinement). Trên cơ sở đó, chương này giới thiệu ý tưởng cải tiến nhằm mở rộng khả năng chuyển phong cách đa ngôn ngữ (cross-lingual style transfer) thông qua việc thay thế và điều chỉnh mô-đun SCR.

- [Chương 4](#) – Thực Nghiệm, Kết Quả và Phân Tích

Chương này mô tả chi tiết quy trình thiết lập thực nghiệm, bao gồm việc xây dựng tập dữ liệu đa ngôn ngữ (Latin–Hán), cấu hình huấn luyện và các tiêu chí đánh giá được sử dụng (FID[17], SSIM[18], LPIPS[19], L1, User Study). Đồng thời, chương trình bày các kết quả định lượng, định tính và đánh giá của con người, so sánh mô hình đề xuất (FontDiffuser + CL-SCR) với các mô hình nền tảng (GAN-based và Diffusion-based). Phần phân tích chuyên sâu sẽ đánh giá hiệu quả của mô-đun CL-SCR, nghiên cứu Ablation về các thành phần cải tiến, và thảo luận về ưu điểm, hạn chế cũng như ảnh hưởng của các tham số then chốt (như số lượng mẫu âm, Guidance Scale) đối với khả năng chuyển phong cách đa ngôn ngữ..

- [Chương 5](#) – Kết Luận và Hướng Phát Triển:

Tóm tắt toàn bộ đóng góp chính của khóa luận, bao gồm việc tái hiện pipeline FontDiffuser và đề xuất CL-SCR cho cross-lingual font generation. Đề xuất các hướng nghiên cứu mở rộng, như mở rộng sang nhiều ngôn ngữ hơn (tiếng Việt, tiếng Nhật, tiếng Ả Rập), và áp dụng parameter-efficient fine-tuning (như LoRA[20] hoặc Adapter[21]) để tối ưu tài nguyên huấn luyện.

Chương 2

Cơ sở Lý thuyết và Tổng quan Tài liệu

Trong chương này, khoá luận trình bày hệ thống cơ sở lý thuyết nền tảng về các mô hình sinh (Generative Models) và tổng quan tình hình nghiên cứu trong lĩnh vực sinh phông chữ tự động. Cấu trúc chương đi từ các phương pháp truyền thống dựa trên GAN[1], đến sự trỗi dậy của Mô hình khuếch tán (Diffusion Models)[2]. Đồng thời, phần cuối chương sẽ tập trung phân tích sâu về các kỹ thuật biểu diễn phong cách (Style Representation) và những thách thức đặc thù trong bài toán chuyển đổi đa ngôn ngữ, nhằm làm rõ động lực nghiên cứu cho phương pháp đề xuất tại Chương 3.

2.1. Tổng quan về các phương pháp Sinh phông chữ

Lĩnh vực sinh phông chữ (Font Generation) đã trải qua một sự chuyển dịch mạnh mẽ về mặt công nghệ trong thập kỷ qua. Các phương pháp hiện nay có thể được chia thành hai nhóm chính dựa trên mô hình lõi: Mạng đối nghịch sinh (GANs)[1] và Mô hình khuếch tán (Diffusion Models)[2].

2.1.1. Các phương pháp dựa trên GAN[1] (GAN-based Approaches)


Trước sự bùng nổ của Diffusion Models[2] vào năm 2023, Generative Adversarial Networks (GAN)[1] là hướng tiếp cận chủ đạo (State-of-the-art) cho bài toán này. Các nghiên cứu GAN thường tập trung giải quyết vấn đề tách biệt nội dung (content) và phong cách (style).

2.1.1.1. DG-Font[5] (Deformable Generative Network, CVPR 2021)

DG-Font tiếp cận bài toán sinh phông chữ theo hướng **không giám sát (unsupervised)**, tập trung giải quyết thách thức về sự sai lệch hình học lớn giữa phông

chữ nguồn và phông chữ đích mà các phương pháp chuyển đổi phong cách dựa trên texture thông thường thường thất bại. Thay vì sử dụng dữ liệu cặp (paired data) tốn kém, DG-Font đề xuất một kiến trúc mới cho phép học ánh xạ phong cách trực tiếp từ các tập dữ liệu không gán nhãn.

Đóng góp cốt lõi của mô hình là mô-đun **Feature Deformation Skip Connection (FDSC)**. Cơ chế này hoạt động bằng cách dự đoán các bản đồ dịch chuyển (displacement maps) từ đặc trưng nội dung và phong cách, sau đó áp dụng **tích chập biến dạng (deformable convolution)** lên các đặc trưng cấp thấp. Điều này cho phép mô hình “uốn nắn” cấu trúc không gian của ký tự nguồn sao cho khớp với dáng vẻ của ký tự đích trước khi đưa vào bộ trộn (Mixer) để sinh ảnh cuối cùng. Mặc dù đạt hiệu quả cao trong việc bảo toàn cấu trúc, DG-Font vẫn tồn tại nhược điểm có hưu của dòng GAN là sự mất ổn định khi huấn luyện; đối với các ký tự có sự biến đổi topo học quá lớn (ví dụ từ nét thanh sang nét đậm phá cách), ảnh sinh ra dễ bị hiện tượng đứt nét (broken strokes) hoặc mờ nhòe.



Hình 2.1 — Kiến trúc mạng DG-Font. Mô-đun FDSC đóng vai trò nòng cốt trong việc học biến dạng hình học giữa các ký tự.

2.1.1.2. CF-Font[6] (Content Fusion, CVPR 2023)

CF-Font tiếp cận bài toán sinh phông chữ few-shot theo hướng “**lai ghép**” nội dung (**content fusion**), khắc phục hạn chế của các phương pháp truyền thống vốn chỉ dựa vào một font nguồn (source font) duy nhất. Nhận định rằng sự chênh lệch cấu trúc (topology) giữa font nguồn và font đích là nguyên nhân chính gây ra các lỗi biến dạng, CF-Font đề xuất sử dụng một tập hợp các **font cơ sở** (**basis fonts**) tiêu chuẩn để làm “nguyên liệu” tham chiếu.

Đóng góp cốt lõi của nghiên cứu là mô-đun **Content Fusion Module (CFM)**. Cơ chế này hoạt động bằng cách dự đoán bộ trọng số nhiệt (fusion weights) để **tổ hợp** **tuyến tính** các đặc trưng nội dung từ các font cơ sở. Thay vì phải “uốn nắn” khó khăn từ một hình dạng cố định, mô hình có thể linh hoạt pha trộn các đặc điểm hình học từ nhiều nguồn khác nhau để tạo ra một “khung xương” nội dung tiệm cận nhất với font mục tiêu. Chiến lược này giúp giảm thiểu đáng kể việc mất mát thông tin cấu trúc, tuy nhiên cũng đánh đổi bằng chi phí tính toán cao hơn do phải xử lý đa luồng đầu vào. Ngoài ra, nếu tập font cơ sở không đủ bao quát không gian topo, ảnh sinh ra có thể xuất hiện các vết mờ hoặc bóng ma (ghosting artifacts) tại các vùng giao thoa nét.




Hình 2.2 — Minh họa cơ chế Content Fusion: Các đặc trưng từ tập font cơ sở (Source) được tổ hợp tuyến tính dựa trên bộ trọng số dự đoán (Weights) để xấp xỉ cấu trúc hình học của font mục tiêu.

2.1.1.3. DFS[15] (Few-Shot Text Style Transfer via Deep Feature Similarity, TIP 2020)

DFS đề xuất một cách tiếp cận mới cho bài toán chuyển đổi phong cách few-shot bằng cách khai thác mối tương quan cấu trúc giữa các ký tự. Khác với các phương pháp trước đó thường nén toàn bộ thông tin phong cách vào một vector duy nhất, DFS trích xuất đặc trưng từ từng ảnh tham chiếu riêng biệt thông qua mạng CNN. Đóng

góp quan trọng nhất của mô hình là cơ chế **Deep Feature Similarity**, trong đó một **Ma trận Tương đồng (Similarity Matrix - SM)** được tính toán dựa trên **độ tương quan (cross-correlation)** giữa đặc trưng nội dung của ký tự tham chiếu và ký tự mục tiêu. Các đặc trưng style đã được điều chỉnh sau đó được gộp lại và nối với đặc trưng content, rồi đưa qua decoder đối xứng dạng U-Net để tái tạo ký tự đích trong phong cách mong muốn. Mô hình được huấn luyện end-to-end với LSGAN[22] loss kết hợp loss tái tạo, cho phép sinh ảnh có độ chân thực cao hơn so với các phương pháp chỉ dùng CNN thuần túy.

Cơ chế này hoạt động như một bộ lọc chú ý thông minh: nó cho phép mô hình tự động **gán trọng số lớn hơn cho các ký tự tham chiếu có cấu trúc hình học tương đồng** với ký tự cần sinh (ví dụ: sử dụng nét cong của chữ ‘O’ để hỗ trợ sinh chữ ‘Q’ hoặc ‘C’). Sau đó, các đặc trưng phong cách được trọng số hóa này sẽ được trộn (mix) với đặc trưng nội dung để giải mã thành ảnh kết quả. Mặc dù đạt được độ chính xác cao về chi tiết phong cách nhờ việc “chọn lọc” thông tin, DFS vẫn tồn tại nhược điểm là yêu cầu quá trình **tinh chỉnh (fine-tuning)** cho từng phong cách mới (leave-one-out strategy) để đạt kết quả tối ưu, làm hạn chế khả năng ứng dụng thời gian thực so với các mô hình suy diễn trực tiếp (feed-forward).




IR—referenced character	CR—content image of referenced character	CT—content image of target character
IR ₁	CR ₁	Generated Character
IR ₂	CR ₂	
IR ₃	CR ₃	
IR ₄	CR ₄	

Hình 2.3 — Kiến trúc mạng DFS với thành phần cốt lõi là Ma trận Tương đồng (SM) giúp điều hướng dòng chảy thông tin phong cách.

2.1.1.4. FTransGAN[16] (Few-shot Font Style Transfer between Different Languages, WACV 2021)

FTransGAN là một trong những mô hình tiên phong giải quyết bài toán **chuyển đổi phong cách phông chữ đa ngôn ngữ (cross-lingual)** theo hướng few-shot learning. Khác với các phương pháp trước đó thường chỉ tập trung vào chuyển đổi trong cùng một ngôn ngữ, FTransGAN đề xuất một kiến trúc end-to-end cho phép trích xuất thông tin phong cách từ một ngôn ngữ (ví dụ: tiếng Anh) và áp dụng lên nội dung của ngôn ngữ khác (ví dụ: tiếng Trung).

Để giải quyết sự chênh lệch lớn về cấu trúc giữa các hệ chữ viết, FTransGAN thiết kế bộ mã hóa phong cách (Style Encoder) đặc biệt với **cơ chế chú ý đa tầng (multi-level attention)**. Kiến trúc này bao gồm hai mô-đun chính: **Context-aware Attention Network** giúp nắm bắt các đặc trưng cục bộ (như nét bút, hoạ tiết trang trí) và **Layer Attention Network** giúp tổng hợp các đặc trưng toàn cục để quyết định mức độ ưu tiên giữa các tầng đặc trưng khác nhau. Nhờ đó, mô hình có khả năng tạo ra các phông chữ chất lượng cao mà **không cần quá trình tinh chỉnh (fine-tuning)** phức tạp cho từng style mới. Tuy nhiên, FTransGAN vẫn còn hạn chế khi xử lý các phông chữ có tính nghệ thuật quá cao hoặc cấu trúc biến dạng mạnh, đồng thời yêu cầu số lượng ảnh phong cách đầu vào cố định trong quá trình huấn luyện.



Hình 2.4 — Tổng quan kiến trúc FTransGAN.

2.1.2. Mô hình khuếch tán[2] (Diffusion Models)

Gần đây, Mô hình khuếch tán[2] (Diffusion Models) đã tạo nên một cuộc cách mạng trong lĩnh vực thị giác máy tính. Khác với GAN[1] – vốn dựa trên việc lừa mô

hình phân biệt, Diffusion Model mô phỏng quá trình nhiệt động lực học để biến đổi dần dần từ nhiễu sang dữ liệu có ý nghĩa.


Nguyên lý cơ bản gồm hai giai đoạn:

- **Quá trình Khuếch tán xuôi:** phá huỷ dữ liệu một cách có kiểm soát bằng cách thêm nhiễu Gaussian nhiều bước.
- **Quá trình Khuếch tán ngược:** học cách loại bỏ nhiễu từng bước để tái tạo lại dữ liệu gốc.

Điều này tương tự như việc ta học cách “tô dần” một bức tranh từ nền trắng nhiễu cho đến khi ra ảnh rõ nét.

2.1.2.0.1. Quá trình Khuếch tán xuôi

Trong quá trình này, nhiễu được thêm dần vào dữ liệu qua một loạt các bước. Điều này tương tự như chuỗi Markov, trong đó mỗi bước làm giảm nhẹ dữ liệu bằng cách thêm nhiễu Gauss:



Hình 2.5 — Quá trình Khuếch tán xuôi

Về mặt toán học, có thể được biểu diễn như sau:

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I) \quad (2)$$

- x_0 : ảnh gốc (clean image).
- x_t : ảnh ở bước t sau khi thêm nhiễu.
- β_t : hệ số nhiễu nhỏ (thường $\beta_t \in [10^{-4}, 0.02]$).
- I : ma trận đơn vị, đảm bảo nhiễu độc lập và đồng hướng.

Do tính chất của Gaussian, ta có thể suy ra trực tiếp từ x_0 đến x_t :

$$x_t = \sqrt{\alpha_t}x_0 + \sqrt{1 - \alpha_t}\epsilon, \epsilon \sim \mathcal{N}(0, I) \quad (3)$$

trong đó:


$$\alpha_t = 1 - \beta_t \quad (4)$$

$$\alpha_t = \prod_{s=1}^t \alpha_s \quad (5)$$

Điều này rất quan trọng vì giúp ta không cần sinh tuân tự từng bước mà vẫn có thể lấy mẫu trực tiếp ở bước t bất kì (quan trọng khi huấn luyện batch lớn).

2.1.2.0.2. Quá trình Khuéch tán ngược

Quá trình này nhằm mục đích tái tạo lại dữ liệu gốc bằng cách khử nhiễu bằng một loạt các bước đảo ngược quá trình khuéch tán xuôi.



Hình 2.6 — Quá trình Khuéch tán ngược

Về mặt toán học, có thể được biểu diễn như sau:

$$p_\theta(x_{t-1} | x_t) = \mathcal{N}\left(x_{t-1}; \mu_\theta(x_t, t), \sum_\theta(x_t, t)\right) \quad (6)$$

với μ_θ được tính như sau:

$$\mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \alpha_t}} \epsilon_\theta(x_t, t) \right) \quad (7)$$

Ở đây, $\epsilon_\theta(x_t, t)$ là nhiễu do mạng nơ-ron dự đoán, đóng vai trò trung tâm trong việc phục hồi ảnh gốc.

Trong huấn luyện, mô hình được tối ưu để giảm sai số giữa $\epsilon_\theta(x_t, t)$ và nhiễu thực ϵ mà ta đã thêm ở forward process.

2.1.2.0.3. Loss function

Hàm mất mát được sử dụng phổ biến nhất là **Mean Squared Error (MSE)**:

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} [\| \epsilon - \epsilon_\theta(x_t, t) \|^2] \quad (8)$$

Điều này tương đương với việc tối đa hóa khả năng tái tạo phân phối dữ liệu gốc (variational lower bound). Các nghiên cứu gần đây (v-prediction, hybrid loss) cho thấy việc dự đoán trực tiếp v_t hoặc x_0 có thể cải thiện chất lượng ảnh sinh, nhưng MSE vẫn là chuẩn mực trong nhiều ứng dụng như FontDiffuser.

2.1.2.1. FontDiffuser[4] (AAAI 2024)

FontDiffuser là công trình tiên phong áp dụng thành công Diffusion Model vào bài toán One-shot Font Generation. Pipeline của mô hình giải quyết ba vấn đề cốt lõi:

- **Bảo toàn cấu trúc:** Sử dụng khối **MCA (Multi-Scale Content Aggregation)** để tổng hợp thông tin cấu trúc từ toàn cục đến chi tiết.
- **Xử lý biến dạng:** Sử dụng khối **RSI (Reference-Structure Interaction)** thay thế cho các phương pháp biến dạng cũ, giúp tương thích tốt hơn giữa cấu trúc ảnh nguồn và phong cách ảnh đích.
- **Học phong cách:** Sử dụng mô-đun **SCR (Style Contrastive Refinement)** để tinh chỉnh biểu diễn phong cách.

Đây chính là mô hình cơ sở (baseline) mà khoá luận này lựa chọn để kế thừa và phát triển.

2.2. Lý thuyết về Biểu diễn Phong cách (Style Representation)

Trong bài toán sinh phông chữ One-shot, đặc biệt là trong bối cảnh chuyển đổi đa ngôn ngữ (Cross-Lingual), việc trích xuất và biểu diễn chính xác “phong cách” (style) là yếu tố quyết định sự thành bại của mô hình.

2.2.1. Neural Style Transfer truyền thống

Các phương pháp sơ khai (như Gatys et al.[23]) thường sử dụng Ma trận Gram (Gram Matrix) tính toán trên các bản đồ đặc trưng (feature maps) của mạng VGG pre-trained để định nghĩa phong cách. Tuy nhiên, phương pháp này chủ yếu nắm bắt các đặc trưng về chất liệu (texture) và hoạ tiết cục bộ. Đối với ký tự, “phong cách” không chỉ là vân bì mặt mà còn bao gồm các yếu tố hình học cấp cao như: độ gãy khúc, kiểu chân chữ (serif/sans-serif), và cách kết thúc nét (stroke ending). Gram Matrix thường thất bại trong việc hướng dẫn mô hình áp dụng các đặc trưng này lên các cấu trúc hình học mới, dẫn đến kết quả bị biến dạng hoặc chỉ đơn thuần là phủ texture lên ảnh nội dung.

2.2.2. Học tương phản (Contrastive Learning)

Để khắc phục hạn chế trên, các nghiên cứu hiện đại (trong đó có FontDiffuser) chuyển sang hướng **Học biểu diễn tương phản** (**Contrastive Representation Learning**). Tư tưởng cốt lõi là học một không gian embedding phong cách (style latent space) sao cho:

- Các mẫu có cùng phong cách (Positive samples) được kéo lại gần nhau.
- Các mẫu khác phong cách (Negative samples) bị đẩy ra xa nhau.

Hàm mất mát InfoNCE[24] thường được sử dụng để tối ưu hóa không gian này:

$$\mathcal{L}_{\text{NCE}} = -\log \left(\frac{\exp(\text{sim}(z, z^+)/\tau)}{\exp(\text{sim}(z, z^+)/\tau) + \sum_k \exp(\text{sim}(z, z_k^-)/\tau)} \right) \quad (9)$$

Trong FontDiffuser, mô-đun SCR áp dụng tư tưởng này để giám sát bộ mã hóa phong cách. Tuy nhiên, module này ban đầu được thiết kế cho cùng một ngôn ngữ (Hán → Hán). Khi áp dụng sang bài toán Cross-Lingual, đặc biệt là dùng chữ Latin làm mẫu phong cách, các phương pháp chọn mẫu âm (negative selection) thông thường trở nên kém hiệu quả do khoảng cách miền (domain gap) quá lớn giữa hai hệ chữ.

2.3. Thách thức trong bài toán Cross-Lingual: Chuyển đổi Hai chiều giữa Latin và Hán tự

Khác với các hướng tiếp cận truyền thống thường chỉ tập trung vào một chiều chuyển đổi đơn lẻ, khoa luận giải quyết bài toán tổng quát và thách thức hơn là chuyển đổi phong cách hai chiều (Bidirectional Style Transfer) giữa hệ chữ Latin và Hán tự. Sự khác biệt nền tảng giữa hai hệ chữ này đặt ra những rào cản kỹ thuật đặc thù cho từng hướng chuyển đổi, chủ yếu xoay quanh sự bất đối xứng về thông tin và hình thái học.

2.3.1. Vấn đề Chênh lệch Mật độ Thông tin (Information Density Gap)

Thách thức đầu tiên và cốt lõi nhất xuất phát từ **Sự bất cân xứng về mật độ thông tin**, tạo ra hai bài toán ngược chiều nhau. Ở hướng chuyển đổi từ Latin sang Hán tự (e2c), mô hình đổi mới với bài toán “Ngoại suy” (Extrapolation), nơi nó phải học cách trích xuất phong cách từ các ký tự Latin có cấu trúc cực kỳ đơn giản (như chữ I hay 0) để áp dụng lên các Hán tự có kết cấu rập rạp và phức tạp (như chữ 龍 -

Rõng). Nếu không có cơ chế suy diễn tốt, mô hình sẽ không biết cách “tưởng tượng” để lắp đầy phong cách vào các nét phức tạp, dẫn đến hiện tượng ảnh sinh bị dính bết (blob) hoặc mất chi tiết. Ngược lại, ở hướng Hán tự sang Latin (c2e), bài toán trở thành “Trùu tượng hóa” (Abstraction). Lúc này, ảnh nguồn chứa quá nhiều thông tin chi tiết về bút pháp và kết cấu; thách thức đặt ra là làm sao để mô hình biết cách “lọc bỏ” các nhiễu cấu trúc thừa thãi, chỉ giữ lại phần thái phong cách để áp dụng lên khung xương đơn giản của chữ Latin. Nếu thất bại, hiện tượng “rò rỉ nội dung” (content leakage) sẽ xảy ra, khiến chữ Latin sinh ra bị méo mó và trông giống như một bộ thủ Hán tự.

2.3.2. Khoảng cách Hình thái học (Morphological Gap)

Bên cạnh đó, **Khoảng cách hình thái học** (Morphological Gap) giữa hai hệ chữ cũng là một rào cản lớn ngăn cản việc chuyển giao phong cách trực tiếp. Chữ Latin được xây dựng trên tư duy tuyến tính với độ rộng ký tự biến thiên, trong khi Hán tự tuân theo quy tắc khối vuông (block-based) với kích thước cố định. Hơn nữa, các đặc trưng cục bộ như chân chữ (serif) hay điểm kết thúc (terminal) trong tiếng Anh không có sự tương quan một-một trực tiếp với các nét (strokes) hay bộ thủ trong tiếng Trung. Chính vì những sự khác biệt căn bản này, việc áp dụng trực tiếp các mô-đun học phong cách truyền thống (như SCR nguyên bản) thường không hiệu quả. Đây chính là động lực để khoá luận đề xuất cải tiến thành **CL-SCR**, một cơ chế có khả năng học được các đặc trưng phong cách “bất biến” (invariant features) để chuyển giao thông minh qua lại giữa hai miền dữ liệu đối lập này.

Chương 3

Phương Pháp Đề Xuất

3.1. Giới thiệu chương


Trong chương trước, khoá luận đã phân tích các hạn chế của phương pháp GAN[1] và tiềm năng của Mô hình khuếch tán (Diffusion Models)[2] trong bài toán sinh phông chữ. Dựa trên cơ sở đó, chương này trình bày chi tiết phương pháp nghiên cứu được đề xuất.

Cụ thể, khoá luận kế thừa kiến trúc tiên tiến **FontDiffuser**[4] làm mô hình cơ sở (baseline) và đề xuất một cải tiến quan trọng tại giai đoạn tinh chỉnh phong cách (Phase 2) mang tên **Cross-Lingual Style Contrastive Refinement (CL-SCR)**. Mục tiêu của cải tiến này là giải quyết vấn đề về sự không nhất quán phong cách khi chuyển đổi giữa các hệ ngôn ngữ có cấu trúc khác biệt (như từ chữ Latin sang Hán tự).

Cấu trúc chương bao gồm: trình bày kiến trúc tổng thể của FontDiffuser[4], phân tích cơ chế hoạt động của module SCR gốc, và cuối cùng là chi tiết về giải pháp CL-SCR được đề xuất cho bài toán đa ngôn ngữ.

3.2. Kiến trúc nền tảng FontDiffuser

FontDiffuser được thiết kế dưới dạng một mô hình khuếch tán có điều kiện (Conditional Diffusion Model - CDM), mô hình hoá bài toán sinh phông chữ dưới dạng quy trình “khử nhiễu” (noise-to-denoise).




(a) Conditional Diffusion for Font Generation

(b) Style Contrastive Refinement

Hình 3.1 — Mô hình tổng thể của FontDiffuser gồm 2 giai đoạn:
Tái tạo cấu trúc (Trái) và Tinh chỉnh phong cách (Phải)

Mô hình nhận hai đầu vào chính:

- **Ảnh nội dung (Source Image) x_c :** Cung cấp thông tin về cấu trúc nét, bộ cục của ký tự gốc (ví dụ: một chữ cái Arial cơ bản).



Hình 3.2 — Ví dụ về ảnh nội dung

- **Ảnh phong cách (Reference Image) x_s :** Cung cấp thông tin về kiểu dáng, độ đậm nhạt, serif, và các đặc trưng thẩm mỹ (ví dụ: một chữ cái thư pháp).



Hình 3.3 — Ví dụ về ảnh phong cách

Đầu ra của mô hình là ảnh x_0 — một ký tự mới mang nội dung của x_c nhưng khoác lên mình phong cách của x_s .



Hình 3.4 — Ví dụ về ảnh đầu ra

Quy trình huấn luyện được chia thành hai giai đoạn (phases) tuần tự nhằm đảm bảo chất lượng sinh ảnh tối ưu:

3.2.1. Giai đoạn 1: Tái tạo cấu trúc (Reconstruction Phase)

Mục tiêu của giai đoạn này là huấn luyện mô hình khuếch tán học cách khôi phục lại hình ảnh ký tự mục tiêu từ nhiều, dựa trên điều kiện x_c và x_s . Các thành phần cốt lõi bao gồm:

- **Bộ mã hoá nội dung (E_c) và phong cách (E_s):** Trích xuất đặc trưng ngữ nghĩa.

3.2.1.1. Multi-scale Content Aggregation (MCA):


Đây là cơ chế tổng hợp đặc trưng đa tỉ lệ được thiết kế để giải quyết hạn chế của các phương pháp chỉ dựa vào một mức đặc trưng duy nhất. Khi sinh các ký tự phức tạp, một tầng đặc trưng đơn lẻ thường không thể đồng thời nắm bắt được cả bộ cục tổng thể lẫn những chi tiết tinh vi như nét mảnh, bộ phận nhỏ hoặc các dấu thanh. MCA khắc phục điều này bằng cách trích xuất nhiều mức đặc trưng nội dung từ các tầng khác nhau của bộ mã hoá, sau đó đưa chúng vào các khối UNet tương ứng.

Cụ thể, quy trình hoạt động như sau:


1. Ảnh tham chiếu x_c trước hết được nhúng bởi bộ mã hoá nội dung E_c để thu được các đặc trưng đa tỷ lệ $F_c = \{f_c^1, f_c^2, f_c^3\}$ từ các tầng khác nhau.
2. Mỗi đặc trưng nội dung f_c^i được đưa vào UNet thông qua ba khối MCA tương ứng. Tại đây, f_c^i được ghép nối (concatenated) với đặc trưng của khối UNet trước đó là r_i , tạo ra đặc trưng giàu thông tin I_c .
3. Để tăng cường khả năng chọn lọc kênh thích ứng, áp dụng cơ chế chú ý kênh (channel attention) lên I_c . Cơ chế này sử dụng một lớp gộp trung bình (average pooling), hai lớp tích chập 1×1 và một hàm kích hoạt để tạo ra vector nhận biết kênh toàn cục W_c .

4. Vector W_c sau đó được dùng để trọng số hoá I_c thông qua phép nhân theo kênh (channel-wise multiplication).
5. Sau khi đi qua một kết nối phần dư (residual connection), một lớp tích chập 1×1 được sử dụng để giảm số lượng kênh, thu được đầu ra $I_{\{\%}\}$.
6. Cuối cùng, một mô-đun cross-attention được áp dụng để chèn style embedding e_s , trong đó e_s đóng vai trò là Key và Value, còn $I_{\{\%}\}$ đóng vai trò là Query.

Nhờ MCA, mô hình có thể tái hiện chính xác cả những thành phần nhỏ và các nét đặc trưng tinh tế—một yếu tố đặc biệt quan trọng đối với những hệ chữ có độ phức tạp cao, bao gồm các ký tự chứa nhiều bộ thủ hoặc các dấu thanh đòn hỏi độ chính xác cao.



Hình 3.5 — Khối MCA (Multi-scale Content Aggregation)



Hình 3.6 — Đặc trưng Content ở các khối khác nhau

3.2.1.2. Reference-Structure Interaction (RSI):

Giữa ảnh nguồn và ảnh đích thường tồn tại những khác biệt đáng kể về mặt cấu trúc (ví dụ: kích thước phông chữ) cũng như sự lệch lạc về vị trí không gian (spatial misalignment) giữa đặc trưng của UNet và đặc trưng tham chiếu. Để giải quyết vấn đề này, nhóm tác giả đã đề xuất khái Tương tác Cấu trúc - Tham chiếu (RSI). Khối này sử dụng mạng tích chập biến hình (Deformable Convolutional Networks - DCN) để thực hiện biến đổi cấu trúc ngay trên kết nối tắt (skip connection) của UNet.

Điểm khác biệt so với các phương pháp trước đây là thay vì sử dụng CNN truyền thống để tính toán độ lệch (offset) δ_{offset} — vốn hạn chế trong việc nắm bắt thông tin toàn cục — nhóm tác giả đã tích hợp cơ chế Cross-Attention để kích hoạt các tương tác tầm xa (long-distance interactions).

Quy trình cụ thể diễn ra như sau:

1. Ảnh tham chiếu x_c trước hết được nhúng bởi bộ mã hoá nội dung E_c để thu các bản đồ cấu trúc (structure maps) $F_s = \{f_s^1, f_s^2\}$.
2. Tại mỗi tầng, RSI tiếp nhận các đặc trưng từ UNet (r_i) và bản đồ cấu trúc tương ứng (f_s^i). Cả hai được làm phẳng (flatten) thành chuỗi vector S_r và S_s .
3. Cơ chế Cross-Attention được áp dụng để tính toán vùng quan tâm (region of interest) thông qua phép chiếu tuyến tính ϕ :
 - **Query (Q):** Được tạo ra từ đặc trưng tham chiếu $S_s(\phi_q(S_s))$.
 - **Key (K) và Value (V):** Được tạo ra từ đặc trưng UNet $S_r(\phi_k(S_r), \phi_v(S_r))$.
4. Đặc trưng chú ý F_{attn} được tính toán thông qua hàm Softmax, sau đó được đưa qua mạng truyền thẳng (Feed-Forward Network - FFN) để sinh ra độ lệch cấu trúc δ_{offset} .
5. Cuối cùng, DCN sử dụng độ lệch này để “uốn nắn” đặc trưng UNet, tạo ra đầu ra I_R đã được cǎ chỉnh.

$$I_R = \text{DCN}(r_i, \delta_{\text{offset}}) \quad (10)$$

Thông qua cơ chế này, RSI có khả năng trích xuất trực tiếp thông tin cấu trúc từ ảnh tham chiếu và điều chỉnh linh hoạt đặc trưng của ảnh nguồn, đảm bảo sự tương thích về phong cách mà không làm gãy vỡ các nét chi tiết.

3.2.2. Giai đoạn 2: Tinh chỉnh phong cách (Style Refinement Phase)

Mặc dù Giai đoạn 1 có thể tạo ra ký tự rõ nét, nhưng phong cách thường chưa được tách biệt hoàn toàn. Giai đoạn 2 cố định các trọng số của UNet và tập trung huấn luyện module **Style Contrastive Refinement (SCR)**. Module này đóng vai trò như một người hướng dẫn, sử dụng cơ chế học tương phản (Contrastive Learning) để ép buộc mô hình sinh ra ảnh có style vector gần với ảnh tham chiếu nhất có thể.

3.3. Phân tích Module Style Contrastive Refinement (SCR)


3.3.1. Động lực và Kiến trúc

Trong bài toán sinh phông chữ (font generation), mục tiêu cốt lõi của việc sinh phông chữ là đạt được hiệu ứng bắt chước phong cách (style imitation) chính xác, độc lập với sự biến thiên về phong cách giữa ảnh nguồn và ảnh tham chiếu. Trong các mô hình sinh ảnh truyền thống, sự vướng víu (disentanglement) giữa đặc trưng phong cách và nội dung thường không hoàn hảo, dẫn đến kết quả phong cách không nhất quán. Để giải quyết vấn đề này, nhóm tác giả đề xuất một chiến lược mới: xây dựng mô-đun **Style Contrastive Refinement (SCR)**.

Mô-đun Style Contrastive Refinement (SCR) được đề xuất như một chiến lược mới để giải quyết vấn đề này. SCR hoạt động như một cơ chế học biểu diễn (representation learning module) và một bộ giám sát đặc trưng (feature supervisor). Nó không tham gia trực tiếp vào quá trình sinh ảnh pixel-wise của mô hình khuếch tán (diffusion model), mà có nhiệm vụ cung cấp tín hiệu điều hướng, đảm bảo phong cách của ảnh sinh ra (x_0) phải nhất quán với ảnh đích (x_p) ở cả cấp độ toàn cục và cục bộ.

3.3.2. Kiến trúc Khai thác Phong cách (Style Extractor Architecture)

Kiến trúc của SCR, như được minh họa trong thiết kế hệ thống, bao gồm hai thành phần chính:



Hình 3.7 — Minh họa mô-đun SCR

1. Bộ trích xuất Đặc trưng (Style Extractor):

- Sử dụng một mạng VGG (lấy cảm hứng từ Zhang et al. 2022) để nhúng ảnh phông chữ, khai thác các đặc tính phong cách và cấu trúc.
- Để bao phủ đầy đủ cả phong cách cục bộ (như nét bút, serifs) và toàn cục (như độ đậm, độ nghiêng), bộ trích xuất chọn ra N tầng feature maps, ký hiệu là $F_v = \{f_v^0, f_v^1, \dots, f_v^N\}$.

2. Bộ chiếu Đặc trưng (Style Projector):

- Các feature maps F_v được đưa vào bộ chiếu. Tại đây, áp dụng đồng thời **average pooling** và **maximum pooling** để trích xuất các đặc trưng kênh toàn cục khác nhau.
- Kết quả từ hai phép pooling được nối (concatenate) theo chiều kênh, tạo thành đặc trưng tổng hợp F_g .
- Cuối cùng, F_g được đưa qua các phép chiếu tuyến tính (linear projections) để thu được các **vector phong cách** $V = \{v^0, v^1, \dots, v^N\}$. Các vector này đóng vai trò là đầu vào cho hàm mất mát tương phản.

3.3.3. Cơ chế Học Tương phản và Hàm Mất mát (Contrastive Learning and Loss Function)

SCR sử dụng chiến lược học tương phản (Contrastive Learning), vận dụng hàm mất mát L_{sc} để điều hướng mô hình khuếch tán.

3.3.3.1. Chiến lược Thiết lập Mẫu (Sampling Strategy)

Để đảm bảo tính liên quan về nội dung nhưng phân biệt rõ ràng về phong cách, SCR lựa chọn mẫu cẩn thận:

- **Mẫu sinh ra (Generated Sample - x_0):** Ảnh được tạo ra bởi mô hình khuếch tán.
- **Mẫu dương (Positive Sample - x_p):** Là ảnh đích (target image) mang phong cách mong muốn.
 - Để tăng cường **tính bền vững (robustness)** của quá trình bắt chước phong cách, một chiến lược tăng cường dữ liệu (augmentation strategy) được áp dụng trên x_p , bao gồm **cắt ngẫu nhiên (random cropping)** và **thay đổi kích thước ngẫu nhiên (random resizing)**.
- **Mẫu âm (Negative Samples - x_n):** Là K mẫu ảnh có **cùng nội dung** ký tự với x_p và x_0 nhưng mang **phong cách khác biệt**.

3.3.3.2. Định nghĩa hàm mất mát

Hàm mất mát L_{sc} (còn được gọi là L_{SCR} trong công thức tổng thể) là một dạng của hàm **InfoNCE[24]** được tính tổng trên N tầng đặc trưng:

$$L_{sc} = - \sum_{l=0}^{N-1} \log \frac{\exp(v_0^l \cdot v_p^l / \tau)}{(\exp(v_0^l \cdot v_p^l / \tau) + \sum_{i=1}^K \exp(v_0^l \cdot v_{n_i}^l / \tau))} \quad (11)$$

Trong đó:

- Extract biểu thị bộ trích xuất phong cách: $V_0 = \text{Extract}(x_0)$, $V_p = \text{Extract}(x_p)$, $V_n = \text{Extract}(x_n)$.
- $v_0^l, v_p^l, v_{n_i}^l$: lần lượt là vector lớp thứ l của ảnh sinh, ảnh dương và ảnh âm.
- $v_0^l \cdot v_p^l$: biểu thị độ tương đồng cosine (dot product) giữa hai vector phong cách.
- K : Số lượng mẫu âm.
- τ : siêu tham số nhiệt độ (temperature hyper-parameter), được thiết lập ở mức 0.07.

Qua việc tối thiểu hóa hàm mất mát này, mô hình được định hướng để kéo vector phong cách của ảnh sinh lại gần vector của ảnh đích, đồng thời đẩy xa khỏi các vector của các phong cách không mong muốn.

3.4. Kết hợp vào Mục tiêu Huấn luyện (Training Objective)

Để đạt được sự cân bằng giữa việc tái tạo nội dung chính xác và bắt chước phong cách tinh tế, quy trình huấn luyện của FontDiffuser áp dụng chiến lược **hai giai đoạn: từ thô đến tinh (coarse-to-fine two-phase strategy)**.

1. Giai đoạn 1: Tái tạo Cơ bản (Phase 1 - Coarse Stage):

Trong giai đoạn đầu, mục tiêu là tối ưu hoá FontDiffuser để mô hình đạt được năng lực nền tảng trong việc tái tạo cấu trúc phông chữ (font reconstruction). Tại bước này, mô-đun SCR **chưa được kích hoạt**. Hàm mất mát tổng thể cho giai đoạn 1 (L_{total}^1) là sự kết hợp của ba thành phần:

$$L_{\text{total}}^1 = L_{\text{MSE}} + \lambda_{\text{cp}}^1 L_{\text{cp}} + \lambda_{\text{off}}^1 L_{\text{offset}} \quad (12)$$

Chi tiết các thành phần:

- **Hàm mất mát Khuếch tán Tiêu chuẩn (L_{MSE}):** Đây là hàm mất mát cơ bản của mô hình khuếch tán, chịu trách nhiệm tính toán sai số giữa nhiễu dự đoán ε_θ và nhiễu thực tế ε tại bước thời gian t , với điều kiện đầu vào là ảnh nội dung x_c và ảnh phong cách x_s :

$$L_{\text{MSE}} = \|\varepsilon - \varepsilon_{\theta(x_t, t, x_c, x_s)}\|^2 \quad (13)$$

- **Hàm mất mát Nhận thức Nội dung (L_{cp} - Content Perceptual Loss):** Thành phần này được sử dụng để trừu phạt sự lệch lạc về nội dung (content misalignment) giữa ảnh sinh ra x_0 và ảnh đích x_{target} . Khoa luận sử dụng các đặc trưng được mã hoá bởi mạng VGG ($\mathcal{VGG}_{l(\cdot)}$) trên L tầng được chọn:

$$L_{\text{cp}} = \sum_{l=1}^L \|\text{VGG}_l(x_0) - \text{VGG}_l(x_{\text{target}})\| \quad (14)$$

- **Hàm mất mát Độ lệch (L_{offset} - Offset Loss):** Được thiết kế riêng cho mô-đun RSI (Reference-Structure Interaction), hàm này ràng buộc độ lớn của các vector dịch chuyển δ_{offset} nhằm ngăn chặn các biến dạng cấu trúc quá mức, trong đó mean là phép tính trung bình:

$$L_{\text{offset}} = \text{mean}(\|\delta_{\text{offset}}\|) \quad (15)$$

Các siêu tham số trọng số cho giai đoạn 1 được thiết lập là: $\lambda_{\text{cp}}^1 = 0.01$ và $\lambda_{\text{off}}^1 = 0.5$.

2. Giai đoạn 2: Tinh chỉnh Phong cách (Phase 2 - Fine Stage):

Sau khi mô hình đã nắm bắt được cấu trúc, giai đoạn 2 sẽ kích hoạt mô-đun **SCR (Style Contrastive Refinement)**. Mục đích là tích hợp hàm mất mát tương phản phong cách (L_{sc}) để cung cấp tín hiệu hướng dẫn (guidance), giúp mô hình khuếch tán tinh chỉnh các chi tiết phong cách ở cả cấp độ toàn cục và cục bộ.

Hàm mất mát tổng thể cho giai đoạn 2 (L_{total}^2) được mở rộng như sau:

$$L_{total}^2 = L_{MSE} + \lambda_{cp}^2 L_{cp} + \lambda_{off}^2 L_{offset} + \lambda_{sc}^2 L_{sc} \quad (16)$$

Trong giai đoạn này, các trọng số được giữ nguyên cho các thành phần trước và bổ sung trọng số cho thành phần mới:

- $\lambda_{cp}^2 = 0.01$ (trọng số nội dung)
- $\lambda_{off}^2 = 0.5$ (trọng số độ lệch RSI)
- $\lambda_{sc}^2 = 0.01$ (trọng số tương phản phong cách)

Việc bổ sung L_{sc} (như đã định nghĩa ở Phương trình 4 trong phần phân tích SCR) đóng vai trò then chốt trong việc đảm bảo ảnh đầu ra không chỉ đúng về cấu trúc (nhờ L_{cp}, L_{offset}) mà còn đạt độ chân thực cao về phong cách nghệ thuật.

3.5. Cải tiến đề xuất: Cross-Lingual Style Contrastive Refinement (CL-SCR)

3.5.1. Hạn chế của SCR trong bối cảnh đa ngôn ngữ

Mô-đun SCR tiêu chuẩn (Standard SCR) hoạt động dựa trên giả định rằng ảnh nguồn và ảnh tham chiếu chia sẻ cùng một không gian hình thái (cùng một ngôn ngữ). Tuy nhiên, khi mở rộng sang bài toán **Cross-Lingual Font Generation** (Huấn luyện trên dữ liệu tiếng Latin đơn giản D_{source} , ứng dụng sang chữ cái Hán D_{target} phức tạp), SCR bộc lộ điểm yếu về **thiên kiến cấu trúc (structural bias)**.

Cụ thể, bộ trích xuất đặc trưng StyleExtractor (sử dụng các tầng VGG pre-trained) có xu hướng “học vẹt” các đặc điểm cấu trúc dày đặc của Hán tự thay vì trích xuất phong cách trừu tượng. Khi gấp các ký tự Latin với cấu trúc thưa, sự chênh lệch miền (domain gap) khiến vector phong cách v_{gen} và v_{target} không còn tương đồng trong không gian tiềm ẩn.

3.5.2. Thiết kế module CL-SCR

Để giải quyết vấn đề này, khoá luận đề xuất mô-đun **Cross-Lingual SCR (CL-SCR)**. Dựa trên mã nguồn đã xây dựng, CL-SCR không thay đổi kiến trúc cốt lõi của StyleExtractor hay Projector, mà thay đổi **chiến lược lấy mẫu (sampling strategy)** và **cơ chế tính hàm mất mát đa luồng**.

3.5.2.1. Chiến lược lấy mẫu mở rộng

Thay vì chỉ sử dụng cặp mẫu dương/âm đơn thuần (Intra-lingual), CL-SCR thiết lập đầu vào cho hàm forward của mô hình bao gồm hai luồng dữ liệu song song:

1. Luồng Nội miền (Intra-Lingual Flow):

- Anchor (x_{gen}): Ảnh sinh ra từ mô hình Diffusion.
- Intra-Positive ($x_{\text{pos}}^{\text{intra}}$): Ảnh cùng nội dung ký tự, cùng phong cách (Ground Truth tiếng Trung). Giúp mô hình giữ vững cấu trúc cơ bản.
- Intra-Negative ($x_{\text{neg}}^{\text{intra}}$): Ảnh cùng nội dung, khác phong cách.

2. Luồng Xuyên miền (Cross-Lingual Flow - Điểm cải tiến chính):

- Cross-Positive ($x_{\text{pos}}^{\text{cross}}$): Các ảnh thuộc ngôn ngữ đích (Chữ cái Latin) mang cùng Style ID với ảnh tham chiếu. Mục tiêu là ép buộc bộ Projector phải ánh xạ các đặc trưng từ hai ngôn ngữ khác nhau về cùng một cụm vector nếu chúng có cùng phong cách.
- Cross-Negative ($x_{\text{neg}}^{\text{cross}}$): Các ảnh thuộc ngôn ngữ đích có cấu trúc nét tương đồng nhưng khác phong cách (Hard Negative Mining).

3.5.2.2. Cơ chế tính toán Loss hỗn hợp

Hàm mất mát CL-SCR được định nghĩa là tổ hợp tuyến tính giữa mất mát nội miền và mất mát xuyên miền:

$$L_{\text{CL-SCR}} = \alpha_{\text{intra}} \cdot L_{\text{intra}} + \beta_{\text{cross}} \cdot L_{\text{cross}} \quad (17)$$

Trong đó: α_{intra} và β_{cross} là các siêu tham số trọng số (được thiết lập lần lượt là 0.3 và 0.7 trong thực nghiệm) nhằm ưu tiên khả năng chuyển giao phong cách sang ngôn ngữ đích.

Thành phần **Cross-Lingual InfoNCE Loss** (L_{cross}) được tính toán bằng cách tổng hợp qua L tầng đặc trưng (từ relu1_1 đến relu5_1 của VGG):

$$L_{\text{cross}} = - \sum_{l=1}^L \log \frac{\exp(v_{\text{gen}}^l \cdot v_{\text{pos,cross}}^l / \tau)}{\exp(v_{\text{gen}}^l \cdot v_{\text{pos}_l, \text{cross}}^l / \tau) + \sum_{k=1}^K \exp(v_{\text{gen}}^l \cdot v_{\text{neg}_k, \text{cross}}^l / \tau)} \quad (18)$$

Với $v = \text{Projector}(\text{Extractor}(x))$ là vector phong cách sau khi đi qua mạng chiếu.

3.5.2.3. Quy trình huấn luyện Pha 2 cải tiến

Trong giai đoạn tinh chỉnh (Phase 2), hàm mất mát tổng thể được cập nhật để tích hợp CL-SCR. Việc sử dụng song song cả intra và cross loss giúp mô hình vừa duy trì tính ổn định (nhờ intra) vừa học được tính bát biến của phong cách qua các ngôn ngữ (nhờ cross).

Hàm mục tiêu cuối cùng là:

$$L_{\text{Total}}^2 = L_{\text{MSE}} + \lambda_{\text{content}} L_{\text{content}} + \lambda_{\text{offset}} L_{\text{offset}} + \lambda_{\text{style}} L_{\text{CL-SCR}} \quad (19)$$

Trong đó:

- L_{MSE} đảm bảo ảnh sinh ra không bị biến dạng quá nhiều so với ảnh gốc.
- L_{content} (Content Perceptual Loss) giữ gìn cấu trúc nét chữ.
- L_{offset} kiểm soát độ dịch chuyển của module RSI.
- $L_{\text{CL-SCR}}$ đóng vai trò trọng tâm trong việc chuyển giao phong cách đa ngôn ngữ.

Việc tích hợp CL-SCR kỳ vọng sẽ giúp mô hình “bắt” được các đặc trưng phong cách trừu tượng (như độ xước cọ, độ thanh mảnh) tốt hơn và áp dụng chính xác lên các ký tự Hán phúc tạp.

3.6. Đề xuất thuật toán tính CL-SCR

Thuật toán 3.1 — Thuật toán tính hàm mất mát CL-SCR

Input	S	embedding style anchor rút ra từ sample
	P_{intra}	positive cùng ngôn ngữ (intra-language)
	P_{cross}	positive khác ngôn ngữ (cross-language)
	N_{intra}	negative cùng ngôn ngữ
	N_{cross}	negative khác ngôn ngữ
	α, β	hệ số trọng số cho từng nhánh
	L	số lượng tầng đặc trưng (feature layers)
	mode	{intra, cross, both}
Output	L_{total}	giá trị loss cuối cùng
procedure		
1	CAL_CL_SCR_LOSS($V_{\text{gen}}, V_{p_{\text{intra}}}, V_{n_{\text{intra}}}, V_{p_{\text{cross}}}, V_{n_{\text{cross}}}, \alpha_{\text{intra}}, \beta_{\text{cross}}, \tau$):	
2	$L_{\text{total}} \leftarrow 0.0$	▷ Loss tổng
3	count $\leftarrow 0$	▷ Số nhánh loss được sử dụng
4	if mode $\in \{\text{intra, both}\}$ và $P_{\text{intra}} \neq \emptyset$ then	
5	$L_{\text{intra}} \leftarrow 0$	
6	for $l = 1 \rightarrow L$ do	▷ Duyệt từng tầng embedding
7	$L_{\text{intra}} \leftarrow L_{\text{intra}} +$	
	InfoNEC($S^l, P_{\text{intra}}^l, N_{\text{intra}}^l$)	
8	end for	
9	$L_{\text{intra}} \leftarrow L_{\text{intra}} / L$	▷ Trung bình theo tầng
10	if mode = both then	
11	$L_{\text{total}} \leftarrow L_{\text{total}} + \alpha \cdot L_{\text{intra}}$	▷ Áp dụng trọng số α
12	else	
13	$L_{\text{total}} \leftarrow L_{\text{total}} + L_{\text{intra}}$	
14	end if	
15	count $\leftarrow count + 1$	

```

16 |   end if
17 |   if mode ∈ {cross, both} và  $P_{\text{cross}} \neq$ 
18 |      $\emptyset$  then
19 |        $L_{\text{cross}} \leftarrow 0$ 
20 |       for  $l = 1 \rightarrow L$  do
21 |          $L_{\text{cross}} \leftarrow L_{\text{cross}} +$ 
22 |           InfoNEC( $S^l, P_{\text{cross}}^l, N_{\text{cross}}^l$ )
23 |       end for
24 |        $L_{\text{cross}} \leftarrow L_{\text{cross}} / L$ 
25 |       if mode = both then
26 |          $L_{\text{total}} \leftarrow L_{\text{total}} + \beta \cdot L_{\text{cross}}$       ▷ Áp dụng trọng số  $\beta$ 
27 |       else
28 |          $L_{\text{total}} \leftarrow L_{\text{total}} + L_{\text{cross}}$ 
29 |       end if
30 |       count  $\leftarrow$  count + 1
31 |       if count > 0 then
32 |          $L_{\text{total}} \leftarrow L_{\text{total}} / \text{count}$           ▷ Chuẩn hoá khi có nhiều nhánh
33 |       end if
34 |       return  $L_{\text{total}}$ 
35 |   end if

```

Chương 4

Thực Nghiệm và Đánh Giá Kết Quả

Chương này trình bày chi tiết **thiết lập thực nghiệm**, bao gồm mô tả bộ dữ liệu, các thước đo đánh giá và cấu hình huấn luyện chi tiết trên nền tảng phần cứng giới hạn. Tiếp theo, khoá luận sẽ đưa ra các **so sánh định lượng và định tính giữa phương pháp đề xuất (CL-SCR FontDiffuser) với các phương pháp tiên tiến hiện nay (State-of-the-Art)** nhằm chứng minh hiệu quả trong bài toán sinh phông chữ đa ngôn ngữ (Cross-lingual Font Generation) theo cả hai chiều: **từ Hán tự sang Latin và từ Latin sang Hán tự**.

4.1. Bộ dữ liệu (Datasets)

4.1.1. Cấu trúc

Để đảm bảo tính khách quan và khả năng so sánh công bằng với các nghiên cứu tiên tiến, khoá luận không tự xây dựng dữ liệu mới mà kế thừa **bộ dữ liệu chuẩn** từ công trình “Few-shot Font Style Transfer between Different Languages”[16]. Đây là tập dữ liệu chuyên biệt cho bài toán đa ngôn ngữ, bao gồm **818 bộ phông chữ song ngữ** với độ đa dạng phong cách cao, trải dài từ serif, sans-serif đến thư pháp và viết tay. Cấu trúc dữ liệu được tổ chức thành hai tập con tương tác chặt chẽ nhằm phục vụ bài toán chuyển đổi hai chiều: **tập ký tự Hán** chứa trung bình **800 ký tự** thông dụng (chuẩn GB2312) đóng vai trò miền đích phức tạp, và **tập ký tự Latin** bao gồm **52 ký tự** cơ bản. Đặc điểm cốt lõi của bộ dữ liệu này là **sự nhất quán tuyệt đối về phong cách** giữa hai hệ chữ trong cùng một bộ font, **cung cấp các cặp dữ liệu nhãn (Ground-truth)** tự nhiên giúp mô-đun CL-SCR học được sự tương quan phong cách xuyên ngôn ngữ.

4.1.2. Tiền xử lý và Chuẩn hoá

Quy trình tiền xử lý: Về quy trình tiền xử lý, dữ liệu thô trải qua các bước chuẩn hoá để tối ưu hoá quá trình huấn luyện. Cụ thể, toàn bộ ảnh ký tự được render dưới dạng **thang độ xám (grayscale)** nhằm loại bỏ nhiễu màu sắc, giúp mô hình tập trung tối đa vào việc học các đặc trưng hình học và cấu trúc nét. Các ảnh đầu vào sau đó được chuẩn hoá đồng bộ về kích thước **64 × 64 pixel**, đồng thời áp dụng kỹ thuật **căn chỉnh tự động (auto-centering)** để đưa ký tự về tâm ảnh với tỷ lệ lề phù hợp. Cuối cùng, một bước **lọc bỏ thủ công** được thực hiện để loại trừ các mẫu lỗi như ký tự bị đứt nét hoặc render thiếu, đảm bảo chất lượng đầu vào tốt nhất cho mô hình.

Quy trình Chuẩn hoá và Lấy mẫu Động: Tiếp nối các bước xử lý thô, để đảm bảo tính tương thích tối đa với kiến trúc mạng nơ-ron tích chập và cơ chế khuếch tán, khoá luận thiết lập một **đường ống xử lý dữ liệu** chuyên biệt được triển khai thời gian thực trong quá trình huấn luyện. Cụ thể, thông qua lớp `FontDataset`, mọi ảnh đầu vào (bao gồm ảnh nội dung, ảnh phong cách và các mẫu âm) đều được chuyển đổi đồng bộ sang không gian màu **RGB (3 kênh)** để khớp với đầu vào tiêu chuẩn của bộ mã hóa U-Net. Kế đến, kỹ thuật **nội suy song tuyến tính (Bilinear Interpolation)** được áp dụng để đưa ảnh về độ phân giải mục tiêu, giúp làm mượt các đường biên răng cưa và bảo toàn thông tin cấu trúc tốt hơn so với các phương pháp lấy mẫu lân cận. Về mặt số học, dữ liệu trải qua bước **chuẩn hoá giá trị (Value Normalization)**, chuyển đổi các điểm ảnh từ dải $[0, 255]$ sang dạng Tensor với dải giá trị tiêu chuẩn $[-1, 1]$, tạo điều kiện hội tụ ổn định cho quá trình khử nhiễu Gaussian. Đặc biệt, để phục vụ mô-đun CL-SCR, khoá luận áp dụng chiến lược **Lấy mẫu âm động (Dynamic Negative Sampling)**: thay vì cố định các cặp mẫu, hệ thống tự động truy xuất và lựa chọn ngẫu nhiên K mẫu âm từ kho dữ liệu dựa trên chế độ huấn luyện (nội miền `intra` hoặc xuyên miền `cross`) ngay tại mỗi bước lặp, giúp mô hình liên tục được tiếp xúc với các biến thể phong cách đa dạng và tránh hiện tượng học vẹt.

4.2. Thiết lập Thực nghiệm

4.2.1. Cấu hình Huấn luyện (Implementation Details)

Các thí nghiệm được thực hiện trên môi trường tính toán đám mây Kaggle với **GPU NVIDIA Tesla P100 (16GB VRAM)**. Mã nguồn được triển khai trên nền tảng **PyTorch** và thư viện **Diffusers**.

Quá trình huấn luyện tuân theo chiến lược hai giai đoạn (Two-stage training) với các siêu tham số được thiết lập cụ thể như sau dựa trên tài nguyên phần cứng giới hạn:

1. Giai đoạn Tái tạo (Phase 1 - Reconstruction): Trong giai đoạn khởi đầu này, mục tiêu chính của mô hình là học các đặc trưng cấu trúc nội dung và phong cách cơ bản. Quá trình huấn luyện được thực hiện xuyên suốt **400,000 bước lặp** với kích thước batch được cố định là **4**. Về chiến lược tối ưu hoá, khoá luận sử dụng bộ giải thuật **AdamW** với tốc độ học khởi tạo là 1×10^{-4} , kết hợp cùng lịch trình điều chỉnh Linear bao gồm **10,000 bước khởi động** (warmup steps) để đảm bảo mô hình hội tụ ổn định. Hàm mất mát tổng hợp được cấu hình với các trọng số thành phần cụ thể là $\lambda_{\text{percep}} = 0.01$ cho Content Perceptual Loss và $\lambda_{\text{offset}} = 0.5$ cho Offset Loss nhằm hỗ trợ mô-đun RSI học biến dạng cấu trúc.

2. Tiền huấn luyện mô-đun CL-SCR: Trước khi được tích hợp vào luồng sinh ảnh chính, mô-đun CL-SCR (Cross-Lingual Style Contrastive Refinement) trải qua một quá trình huấn luyện độc lập nhằm xây dựng không gian biểu diễn phong cách tối ưu. Quá trình này được thực hiện trong tổng số **200,000 bước lặp** với kích thước batch là **16**. Khoá luận sử dụng bộ tối ưu hoá Adam để cập nhật tham số cho cả bộ trích xuất đặc trưng (Style Feat Extractor) và bộ chiếu đặc trưng (Style Projector) với tốc độ học cố định là 1×10^{-4} .

Để tăng cường tính bền vững của biểu diễn phong cách đối với các biến thể hình học, khoá luận áp dụng chiến lược tăng cường dữ liệu (Data Augmentation) thông qua kỹ thuật **Random Resized Crop**. Cụ thể, ảnh đầu vào được **cắt ngẫu nhiên với tỷ lệ diện tích từ 75% đến 100% (scale 0.75 - 1.0)** và **tỷ lệ khung hình dao động nhẹ trong khoảng 0.8 đến 1.2**, sau đó được đưa về kích thước chuẩn thông qua nội suy song tuyến tính (bilinear interpolation).

3. Giai đoạn Tinh chỉnh Phong cách (Phase 2 - Style Refinement with CL-SCR): Bước sang giai đoạn hai, mô-đun CL-SCR được kích hoạt để tinh chỉnh sâu các đặc trưng phong cách Latin, trong khi tốc độ học của các thành phần khác được giảm xuống để tránh phá vỡ cấu trúc đã học. Quá trình này diễn ra trong **30,000 bước** với **kích thước batch 4** nhằm dành tài nguyên VRAM cho các tính toán của mô-đun tương phản. Tốc độ học được thiết lập ở mức thấp hơn là 1×10^{-5} , áp dụng chiến lược Constant (hằng số) sau **1,000 bước khởi động**. Đối với cấu hình CL-SCR, khoá luận lựa chọn chế độ huấn luyện kết hợp cả nội miền và xuyên miền (`scr_mode="both"`) với tỷ trọng $\alpha_{\text{intra}} = 0.3$ và ưu tiên $\beta_{\text{cross}} = 0.7$, đồng thời sử

dụng **4 mẫu âm** (negative samples) cho mỗi lần tính toán loss. Hàm mục tiêu tổng thể lúc này là sự kết hợp của các thành phần theo công thức:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{MSE}} + 0.01 \cdot \mathcal{L}_{\text{percep}} + 0.5 \cdot \mathcal{L}_{\text{offset}} + 0.01 \cdot \mathcal{L}_{\text{CL-SCR}} \quad (20)$$

4. Quy trình Inference: Trong quá trình lấy mẫu (Inference), mô hình FontDiffuser[4] được đóng gói thành một Pipeline dựa trên DPM-Solver để tối ưu hoá tốc độ.

Cấu hình Lấy mẫu: Khoá luận sử dụng bộ giải **DPM-Solver++** với số bước suy diễn được cố định là **20** (`num_inference_steps=20`), đây là một sự cân bằng giữa tốc độ tính toán và chất lượng ảnh sinh. Chiến lược hướng dẫn vô điều kiện (Classifier-Free Guidance) được áp dụng với tham số hướng dẫn (s) được xác định trong file cấu hình (`guidance_scale`). Để lấy mẫu, các ảnh đầu vào được tiền xử lý và chuẩn hoá về kích thước (`content_image_size`, `style_image_size`) rồi đưa về Tensor với dải giá trị $[-1, 1]$.

Lấy mẫu Hàng loạt (Batch Sampling): Do khoá luận thực hiện đánh giá định lượng trên một lượng lớn mẫu, quy trình lấy mẫu được tự động hoá thông qua hàm `batch_sampling`, bao phủ cả hai hướng nghiên cứu.

4.2.2. Kịch bản Đánh giá (Evaluation Scenarios)

Để đánh giá toàn diện khả năng của mô hình, khoá luận thiết lập hai kịch bản kiểm thử với độ khó tăng dần (theo chuẩn của FontDiffuser và DG-Font[5]):

- SFUC (Seen Font, Unseen Character):** Font đã xuất hiện trong tập huấn luyện, nhưng ký tự sinh ra chưa từng thấy. Kịch bản này đánh giá khả năng **nội suy phong cách**.
- UFSC (Unseen Font, Seen Character):** Font mới hoàn toàn (chưa từng xuất hiện trong quá trình huấn luyện). Đây là kịch bản quan trọng nhất để đánh giá khả năng **One-shot Generalization** của mô hình đối với phong cách lạ.

4.3. Các thước đo đánh giá (Evaluation Metrics)

4.3.1. Chỉ số Định lượng (Quantitative Metrics)

Khoá luận sử dụng bộ 4 chỉ số tiêu chuẩn trong bài toán sinh ảnh để đánh giá chất lượng ảnh sinh (x) so với ảnh thật (y):

4.3.1.1. L1 (Mean Absolute Error)

Độ đo **L1** tính trung bình giá trị tuyệt đối của sai khác giữa các điểm ảnh (pixel-wise), phản ánh độ chính xác về cường độ điểm ảnh:

$$\mathcal{L}_1 = \frac{1}{N} \sum_{i=1}^N |x_i - y_i| \quad (21)$$

Trong đó N là tổng số điểm ảnh. Giá trị L1 càng nhỏ càng tốt.

4.3.1.2. SSIM (Structural Similarity Index)

Độ đo **SSIM** đánh giá mức độ tương đồng về **cấu trúc, độ sáng và độ tương phản**. Khác với L1, SSIM mô phỏng cách mắt người cảm nhận sự thay đổi cấu trúc:

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (22)$$

Giá trị SSIM nằm trong khoảng [0, 1], giá trị càng cao thể hiện chất lượng ảnh càng tốt.

4.3.1.3. LPIPS (Learned Perceptual Image Patch Similarity)

Độ đo **LPIPS** đánh giá **khoảng cách cảm nhận** dựa trên các đặc trưng trích xuất từ mạng nơ-ron sâu (VGG). Chỉ số này khắc phục nhược điểm của L1/SSIM khi xử lý các ảnh bị mờ nhẹ nhưng vẫn giống về ngữ nghĩa:

$$\text{LPIPS}(x, y) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \|w_l \cdot (f_l^x(h, w) - f_l^y(h, w))\|_2^2 \quad (23)$$

Giá trị LPIPS càng thấp chứng tỏ ảnh sinh càng giống ảnh thật về mặt thị giác tự nhiên.

4.3.1.4. FID (Fréchet Inception Distance)

Độ đo **FID** đánh giá chất lượng tổng thể và độ đa dạng của tập ảnh sinh dựa trên khoảng cách thống kê giữa hai phân bố đặc trưng:

$$\text{FID} = \|\mu_r - \mu_g\|_2^2 + \text{Tr} \left(\sum_r + \sum_g -2 \left(\sum_r \sum_g \right)^{\frac{1}{2}} \right) \quad (24)$$

Giá trị FID càng thấp cho thấy phân bố của ảnh sinh càng tiệm cận với phân bố ảnh thật.

4.3.1.5. Phân tích mối tương quan và Vai trò của bộ độ đo

Việc sử dụng đơn lẻ một độ đo không thể phản ánh toàn diện hiệu năng của mô hình sinh phông chữ, do đó khoá luận kết hợp bốn độ đo trên theo **chiến lược đánh giá đa tầng**. Đầu tiên, ở tầng **đánh giá độ chính xác điểm ảnh** (Pixel-level Accuracy), các chỉ số **L1** và **SSIM** đảm bảo rằng ảnh sinh ra không bị lệch lạc quá nhiều về vị trí không gian so với ảnh mẫu (Ground Truth). Tuy nhiên, đối với các mô hình sinh (Generative Models), việc tối ưu hoá mức L1 thường dẫn đến hiện tượng ảnh bị **làm mờ (blurring effect)** để giảm thiểu sai số trung bình. Để khắc phục, tầng thứ hai tập trung vào **đánh giá chất lượng cảm nhận** (Perceptual Quality) thông qua **LPIPS** và **FID**. Trong khi LPIPS đo lường sự tương đồng trong **không gian đặc trưng (Feature Space)** giúp mô hình được “tha thứ” cho những sai lệch nhỏ về pixel miễn là đặc điểm nhận dạng bảo toàn, thì FID đóng vai trò trọng tâm trong việc đánh giá mức độ “thật” (realism) và **tính đa dạng (diversity)**.

Sự kết hợp giữa SSIM (cấu trúc) và LPIPS (cảm nhận) là đặc biệt quan trọng trong bài toán Cross-lingual, nơi việc giữ cấu trúc chữ quan trọng ngang hàng với việc bắt chước phong cách.

4.3.2. Đánh giá Định tính (Qualitative Study)

Các chỉ số định lượng (Quantitative Metrics) như FID hay LPIPS, mặc dù khách quan, nhưng không thể mô phỏng hoàn toàn gu thẩm mỹ và khả năng đọc hiểu của con người. Do đó, để kiểm chứng tính thực tiễn của phương pháp đề xuất, khoá luận tiến hành một khảo sát **đánh giá chủ quan (Subjective Evaluation)** với sự tham gia của con người.

4.3.2.1. Thiết kế khảo sát

Để đánh giá chất lượng thị giác và tính nhất quán phong cách một cách khách quan nhất theo cảm nhận của con người, khoá luận thiết kế một bảng **khảo sát mù (blind test)** với sự tham gia của tổng cộng **30 tình nguyện viên**. Nhóm khảo sát bao gồm 5 người bạn học chuyên ngành thiết kế đồ họa có kiến thức chuyên sâu về typography và 25 người dùng phổ thông, đảm bảo tính đại diện cho cả đánh giá kỹ thuật và thẩm mỹ công chúng.

Bộ dữ liệu khảo sát được xây dựng từ **20 bộ mẫu ngẫu nhiên** trích xuất từ tập kiểm thử (Test Set), **bao gồm các mẫu đại diện cho cả hai kịch bản chuyển đổi phong cách: từ Hán tự sang Latin và từ Latin sang Hán tự**. Trong mỗi câu hỏi, tình nguyện viên được yêu cầu so sánh kết quả sinh ảnh giữa các mô hình khác nhau. Cụ thể, mỗi mẫu so sánh hiển thị một **ảnh tham chiếu (Reference Style)** (chứa phong cách mục tiêu) và các **ảnh kết quả (Generated Images)** là các ký tự được sinh ra bởi các mô hình cạnh tranh (DG-Font[5], FontDiffuser Baseline[4], và Phương pháp đề xuất Ours). Vị trí hiển thị của các ảnh kết quả được xáo trộn ngẫu nhiên để đảm bảo tính công bằng và loại bỏ thiên kiến vị trí. Tình nguyện viên được yêu cầu chọn ra ảnh có **độ nhất quán phong cách tốt nhất** và **chất lượng hình ảnh tổng thể cao nhất** trong số các lựa chọn.

4.3.2.2. Tiêu chí đánh giá

Thay vì chấm điểm phức tạp, người tham gia được yêu cầu thực hiện đánh giá dựa trên **lựa chọn ưu tiên**. Cụ thể, với mỗi bộ mẫu, tình nguyện viên cần chọn ra một bức ảnh duy nhất mà họ cho là tốt nhất dựa trên sự cân bằng giữa hai tiêu chí cốt lõi. Thứ nhất là **Tính nhất quán phong cách**, tức ảnh sinh ra phải kế thừa chính xác các đặc trưng thị giác của ảnh phong cách (như độ đậm nhạt, kết cấu nét cọ, hoặc kiểu chân chữ serif/sans-serif). Thứ hai là **Tính toàn vẹn nội dung**, tức ký tự sinh ra phải duy trì đúng cấu trúc hình học của ảnh nội dung, đảm bảo tính dễ đọc và không bị biến dạng kỳ quái (ví dụ: chữ 丘 trong kịch bản e2c phải giữ nguyên các nét ngang dọc đặc trưng, không bị lai tạp thành ký tự Latin). Kết quả cuối cùng được định lượng thông qua **Tỷ lệ Uu tiên**, tính bằng phần trăm số phiếu bầu chọn mà mỗi mô hình nhận được trên tổng số lượt đánh giá.

4.4. Kết quả Thực nghiệm và Thảo luận

Trong chương này, khoá luận trình bày toàn bộ kết quả thực nghiệm của mô hình đề xuất. Nội dung bao gồm đánh giá định lượng và định tính chi tiết, nghiên cứu bóc tách (ablation study) về các thành phần kiến trúc, khảo sát người dùng, và phân tích các trường hợp thất bại. Các kết quả này được đối chiếu trực tiếp với nhiều mô hình sinh font hiện đại, bao gồm các mô hình **GAN-based** (DG-Font[5], CF-Font[6], DFS[15], FTransGAN[16]), mô hình **diffusion-based** (FontDiffuser[4]), và các phiên bản mô hình của khoá luận.

Để đánh giá toàn diện khả năng chuyển đổi đa ngôn ngữ, khoá luận thực hiện thực nghiệm trên hai hướng chính với các mục tiêu nghiên cứu và cấu hình mô hình cụ thể, khẳng định giá trị nghiên cứu ngang nhau của bài toán Cross-lingual Font Generation:

1. Hướng Latin → Hán tự: Đây là kịch bản kiểm tra khả năng **chuyển giao phong cách Latin** tinh tế lên **cấu trúc Hán tự** phức tạp. Trong kịch bản này, mô hình cần học các đặc trưng nét (như serif, độ dày nét, góc bo) của hệ chữ Latin và áp dụng chúng lên các ký tự Hán. Mục tiêu là kiểm tra hiệu quả của mô-đun **CL-SCR** trong việc tách biệt phong cách Latin khỏi nội dung Latin, đảm bảo sự nhất quán phong cách khi áp dụng lên hệ chữ có hình thái học khác biệt (Hán tự).

Khoá luận sử dụng hai cấu hình mô hình cho hướng này: $Ours_A$ (sử dụng ký tự A làm ảnh phong cách tham chiếu) và $Ours_{AZ}$ (sử dụng ký tự ngẫu nhiên trong khoảng A đến Z làm ảnh phong cách tham chiếu).

2. Hướng Hán tự → Latin: Đây là kịch bản kiểm tra khả năng **khái quát hoá phong cách Hán tự** phức tạp lên **cấu trúc Latin** đơn giản. Trong kịch bản này, mô hình phải học các đặc trưng phong cách đa dạng (ví dụ: nét bút lông, độ dày-mỏng bất đối xứng) từ Hán tự và áp dụng chúng lên cấu trúc Latin. Sự thành công trong hướng này chứng tỏ mô hình có thể trích xuất các đặc trưng phong cách bậc cao của Hán tự để áp dụng hợp lý lên các ký tự Latin có cấu trúc tuyển tính hơn.

Đối với hướng Hán tự → Latin, khoá luận tiến hành phân loại và đánh giá các kịch bản dựa trên **độ phức tạp của ký tự Hán tự** (số nét M) được sử dụng làm ảnh tham chiếu phong cách, nhằm phân tích độ nhạy của mô hình đối với sự đa dạng của nét:

Bảng 4.1 — Bảng phân loại các kịch bản dựa trên độ phức tạp của ký tự

Cấp độ	Định nghĩa (Số nét M)	Cấu hình Mô hình	Mục tiêu Phân tích
All	Đánh giá tổng thể trên các ký tự Hán tự có số nét ngẫu nhiên.	$Ours_{All}$	Đánh giá hiệu năng trung bình của mô hình trên toàn bộ miền dữ liệu Hán tự.
Easy	Ảnh phong cách là Hán tự có số nét $6 \leq M \leq 10$.	$Ours_{Easy}$	Kiểm tra khả năng học các đặc trưng phong cách từ cấu trúc đơn giản.

Cấp độ	Định nghĩa (Số nét M)	Cấu hình Mô hình	Mục tiêu Phân tích
Medium	Ảnh phong cách là Hán tự có số nét $11 \leq M \leq 20$.	Ours _{Medium}	Kiểm tra hiệu quả của các mô-đun bảo toàn nét (MCA) khi đối mặt với cấu trúc trung bình.
Hard	Ảnh phong cách là Hán tự có số nét $M \geq 21$.	Ours _{Hard}	Đánh giá khả năng trích xuất phong cách từ cấu trúc phức tạp và rậm rạp nhất mà không làm mất thông tin nét.

有更串 噇雕臚 龜巖鑾
 花识莖 磔壇愷 櫺鷗礪
 蛴郇跂 謎𢂑漱 鰐龍龜

Hình 4.1 — Ví dụ ba loại độ phức tạp

Việc phân loại theo độ phức tạp này giúp khoá luận xác định mô-đun CL-SCR hoặc các kiến trúc lõi khác (**MCA**, **RSI**) hoạt động hiệu quả nhất ở mức độ phức tạp cấu trúc nào của phong cách Hán tự, từ đó cung cấp những cái nhìn sâu sắc hơn về khả năng học đặc trưng của mô hình khuếch tán.

4.4.1. So sánh Định lượng (Quantitative Results)

Các bảng dưới đây trình bày kết quả so sánh giữa phương pháp đề xuất (Ours) với các baseline mạnh nhất hiện nay gồm DG-Font[5], CF-Font[6], DFS[15], FTransGAN[16] và trên 2 kịch bản UFSC và SFUC cho tác vụ chuyển đổi phong cách từ chữ Latin sang ảnh nguồn Hán và ngược lại.

4.4.1.1. Tác vụ chuyển đổi phong cách từ chữ Latin sang ảnh nguồn Hán (e2c).

Bảng 4.2 — Kết quả Định lượng cho Latin → Hán tự (e2c) trên SFUC.

Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).

Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
DG-Font[5]	0.2773	0.2702	0.4023	106.3833
CF-Font[6]	0.2659	0.2740	0.3979	91.2134
DFS[15]	0.1844	<u>0.3900</u>	0.3548	40.4561
FTransGAN[16]				
FontDiffuser (Baseline)[4]	0.1976	0.3775	0.2968	14.6871
Ours _A (w/ CL-SCR)	<u>0.1927</u>	0.3912	0.2868	<u>12.3964</u>
Ours _{AZ} (w/ CL-SCR)	0.1939	0.3890	<u>0.2911</u>	11.7691

Bảng 4.3 — Kết quả Định lượng cho Latin → Hán tự (e2c) trên UFSC.
Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).

Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
DG-Font[5]	0.2797	0.2654	0.3649	54.0974
CF-Font[6]	0.2638	0.2716	0.3615	51.3925
DFS[15]	0.2089	0.3048	0.3876	62.7206
FTransGAN[16]				
FontDiffuser (Baseline)[4]	0.2283	0.2946	0.3184	29.0999
Ours _A (w/ CL-SCR)	0.2218	<u>0.3144</u>	0.2892	<u>17.8373</u>
Ours _{AZ} (w/ CL-SCR)	0.2214	0.3197	<u>0.2954</u>	13.5508

Dựa trên số liệu từ [Bảng 4.2](#) và [Bảng 4.3](#), có thể rút ra những đánh giá quan trọng về hiệu năng của phương pháp đề xuất so với các mô hình State-of-the-Art (SOTA). Điểm nổi bật nhất trong kết quả thực nghiệm là **sự cải thiện mang tính đột phá về chất lượng ảnh sinh**, được phản ánh rõ nét qua chỉ số **FID**. Trong kịch bản SFUC (Seen Font), mô hình Ours_{AZ} đạt FID là **11.769**, giảm **khoảng 20%** so với baseline mạnh nhất là FontDiffuser[4] (14.687) và bỏ xa các phương pháp GAN truyền thống. Tuy nhiên, sức mạnh thực sự của mô hình được thể hiện ở kịch bản khó hơn là UFSC

(Unseen Font), nơi mô hình phải sinh ảnh từ các font chưa từng thấy. Tại đây, $Ours_{AZ}$ vẫn duy trì phong độ án tượng với FID 13.551, thấp hơn tới 53% so với FontDiffuser (29.100). Điều này chứng minh rằng mô-đun CL-SCR đã giải quyết triệt để vấn đề “domain gap” giữa chữ Hán và chữ Latin, giúp ảnh sinh ra có độ tự nhiên cao và phân bố sát với ảnh thật, thay vì bị nhiễu hoặc méo mó như mô hình gốc.

Bên cạnh độ tự nhiên, khả năng **bảo toàn cấu trúc** cũng được duy trì ở mức cao. Về chỉ số tương đồng cấu trúc **SSIM**, phương pháp đề xuất $Ours_{AZ}$ dẫn đầu ở cả hai kịch bản (0.389 và 0.320), cho thấy các nét chữ Latin được tái tạo sắc nét. Một điểm đáng lưu ý là mặc dù mô hình **DFS[15]** đạt kết quả tốt nhất về sai số điểm ảnh **L1** (0.1844 ở SFUC), nhưng chỉ số FID của nó lại rất cao (40.456). Đây là minh chứng cho hiện tượng **nghịch lý L1**: các mô hình như DFS[15] hay FTransGAN[16] thường tối ưu hoá bằng cách sinh ra các ảnh “trung bình cộng” bị mờ (blurry) để giảm thiểu sai số pixel, trong khi phương pháp đề xuất dựa trên Diffusion chấp nhận L1 cao hơn một chút để tạo ra các **chi tiết tần số cao** sắc nét và chân thực hơn. Do đó, sự đánh đổi nhỏ về L1 là hoàn toàn hợp lý để đạt được chất lượng thị giác vượt trội.

Cuối cùng, sự so sánh nội bộ giữa hai biến thể tham chiếu ($Ours_A$ và $Ours_{AZ}$) làm nổi bật tính ổn định của mô hình. Kết quả thực nghiệm cho thấy $Ours_{AZ}$ đạt hiệu suất vượt trội hơn hẳn so với $Ours_A$ trên cả hai kịch bản, đặc biệt là sự chênh lệch lớn về FID ở UFSC (13.55 so với 17.84). Điều này dẫn đến kết luận quan trọng rằng mô hình tích hợp CL-SCR có khả năng trích xuất **đặc trưng phong cách bất biến** cực tốt. Việc được huấn luyện với các ký tự ngẫu nhiên (A-Z) thay vì cố định (A) giúp mô hình không bị **học thuộc lòng (overfit)** vào cấu trúc hình học của một ký tự cụ thể, mà thực sự “hiểu” được bản chất của phong cách (như độ đậm nhạt, serif, texture), từ đó đảm bảo độ linh hoạt cao trong các ứng dụng thực tế.

4.4.1.2. Tác vụ chuyển đổi phong cách từ chữ Hán sang ảnh nguồn Latin (c2e).

Bảng 4.4 — Kết quả Định lượng cho Hán tự → Latin (c2e) trên SFUC.

Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).

Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
DG-Font[5]	0.1462	0.5542	0.2821	74.1655
CF-Font[6]	0.1402	0.5621	0.2790	67.1241

Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
DFS[15]	0.1083	0.6140	0.2585	40.4042
FTransGAN[16]				
FontDiffuser (Baseline)[4]	0.1223	0.6107	0.2270	21.2234
Ours _{All} (w/ CL-SCR)	0.1083	0.6406	0.2019	14.7298
Ours _{Easy} (w/ CL-SCR)	0.1079	0.6413	0.2018	14.6558
Ours _{Medium} (w/ CL-SCR)	<u>0.1082</u>	<u>0.6406</u>	<u>0.2024</u>	<u>14.8556</u>
Ours _{Hard} (w/ CL-SCR)	0.1114	0.6318	0.2084	15.7662

Bảng 4.5 — Kết quả Định lượng cho Hán tự → Latin (c2e) trên UFSC.
Mũi tên chỉ hướng tốt hơn (thấp hơn hoặc cao hơn).

Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
DG-Font[5]	0.1397	0.5624	0.2751	89.8197
CF-Font[6]	0.1317	0.5756	0.2726	84.3787
DFS[15]	0.1139	0.5819	0.2907	75.2760
FTransGAN[16]				
FontDiffuser (Baseline)[4]	0.1370	0.5731	0.2476	59.5788
Ours _{All} (w/ CL-SCR)	0.1090	0.6377	0.1985	41.1152
Ours _{Easy} (w/ CL-SCR)	<u>0.1050</u>	<u>0.6439</u>	<u>0.1945</u>	<u>41.7273</u>
Ours _{Medium} (w/ CL-SCR)	0.1029	0.6466	0.1929	43.6918
Ours _{Hard} (w/ CL-SCR)	0.1050	0.6444	0.1982	45.5486

Dựa trên số liệu từ [Bảng 4.4](#) và [Bảng 4.5](#), kết quả thực nghiệm cho thấy **phương pháp đề xuất (Ours) đạt được sự cải thiện toàn diện so với các mô hình SOTA**, đồng thời hé lộ mối tương quan thú vị giữa độ phức tạp của Hán tự và hiệu quả chuyển đổi phong cách.

Thứ nhất, xét về hiệu năng tổng thể, mô hình đề xuất vượt trội hoàn toàn so với Baseline FontDiffuser[4] ở cả hai kịch bản. Trên tập dữ liệu quen thuộc SFUC, cấu hình Ours_{Easy} **đạt mức FID thấp kỷ lục 14.656, giảm khoảng 31% so với Baseline (21.223)**. Sự chênh lệch càng trở nên rõ rệt hơn ở kịch bản khó UFSC (Unseen Font), nơi Ours_{All} **đạt FID 41.115**, thấp hơn đáng kể so với mức **59.579 của Baseline**. Điều này khẳng định rằng mô-đun CL-SCR không chỉ hiệu quả trong việc tinh chỉnh phong cách nội tại mà còn giúp mô hình tổng quát hoá tốt hơn khi phải đổi mặt với các phong cách Hán tự lạ lẫm, phức tạp để áp dụng lên cấu trúc Latin đơn giản. So với các phương pháp GAN (DG-Font[5], CF-Font[6]) hay FTransGAN[16] vốn có chỉ số FID rất cao (trên 80 ở UFSC), phương pháp đề xuất chứng minh ưu thế tuyệt đối về độ tự nhiên và tính thẩm mỹ của ảnh sinh.

Thứ hai, phân tích sâu về độ phức tạp nét (stroke complexity) thông qua các biến thể Easy, Medium và Hard mang lại những góc nhìn giá trị. Tại bảng [Bảng 4.5](#), có thể thấy cấu hình Ours_{Medium} **đạt kết quả tốt nhất về các chỉ số cấu trúc và điểm ảnh (L1 thấp nhất 0.1029, SSIM cao nhất 0.6466)**. Điều này gợi ý rằng **các Hán tự có số nét trung bình (11-20 nét) là điểm ngọt để trích xuất phong cách**: chúng cung cấp đủ thông tin về bút pháp và kết cấu (hơn Easy) nhưng không gây ra quá nhiều nhiễu cấu trúc (structural noise) như các ký tự Hard (trên 21 nét). Khi sử dụng các ký tự quá phức tạp (Hard) để chuyển phong cách sang chữ Latin (vốn rất đơn giản), mô hình dễ gặp khó khăn trong việc lược bỏ các chi tiết thừa, dẫn đến chỉ số FID và L1 của Ours_{Hard} thường kém hơn so với Easy và Medium.

Cuối cùng, mặc dù Ours_{Medium} tối ưu về cấu trúc, nhưng Ours_{All} lại đạt chỉ số FID tốt nhất trên tập UFSC (41.115). Điều này cho thấy **việc tiếp xúc với đa dạng các mức độ phức tạp trong quá trình huấn luyện giúp mô hình xây dựng được không gian biểu diễn phong cách phong phú nhất**, từ đó sinh ra các hình ảnh có độ tự nhiên cao nhất về mặt cảm nhận thị giác, ngay cả khi độ chính xác từng điểm ảnh (L1) thua kém nhẹ so với cấu hình chuyên biệt Medium.

4.4.2. So sánh Định tính (Qualitative Analysis)

4.4.3. Đánh giá Cảm nhận Người dùng (User Study)

4.5. Nghiên cứu Bóc tách (Ablation Study)

Trong phần này, khoá luận thực hiện các phân tích chuyên sâu nhằm định lượng đóng góp cụ thể của từng thành phần kỹ thuật trong phương pháp đề xuất. Để đảm bảo tính tập trung và sức thuyết phục của các kết luận, thay vì dàn trải thí nghiệm trên mọi biến thể, khoá luận cố định và lựa chọn hai cấu hình đại diện tiêu biểu nhất làm cơ sở so sánh:

1. Đối với hướng Latin → Hán tự (e2c): Khoá luận sử dụng cấu hình Ours_{AZ}. Đây là cấu hình chịu áp lực tổng quát hoá lớn nhất (do phải xử lý style ngẫu nhiên) và cũng là cấu hình đạt hiệu năng cao nhất trong các thực nghiệm trước đó. Việc chứng minh hiệu quả trên cấu hình “khó” nhất này sẽ khẳng định tính đúng đắn và mạnh mẽ (robustness) của các cải tiến đề xuất.

2. Đối với hướng Hán tự → Latin (c2e): Khoá luận sử dụng cấu hình Ours_{All}. Do đặc thù độ phức tạp nét đa dạng của Hán tự, cấu hình này bao quát toàn bộ phổ dữ liệu huấn luyện, cung cấp cái nhìn toàn diện về độ ổn định của mô hình thay vì chỉ tập trung vào một tập con cụ thể (như Easy hay Hard).

Các thí nghiệm dưới đây sẽ lần lượt đánh giá tác động của bốn yếu tố then chốt: các mô-đun kiến trúc, kỹ thuật tăng cường dữ liệu, chế độ hàm mất mát và số lượng mẫu âm.

4.5.1. Ảnh hưởng của các mô-đun trong FontDiffuser

Để xác định đóng góp cụ thể của từng thành phần trong kiến trúc tổng thể, đặc biệt là hiệu quả của mô-đun đề xuất so với bản gốc, khoá luận tiến hành **thực nghiệm bóc tách (Ablation Study)** bằng cách **thay thế và bổ sung dần các mô-đun vào mạng nền tảng**. Bốn mô-đun được khảo sát bao gồm:

- **M: Multi-scale Content Aggregation (MCA)** - Tổng hợp nội dung đa quy mô.
- **R: Reference-Structure Interaction (RSI)** - Tương tác cấu trúc tham chiếu.
- **S: Style Contrastive Refinement (SCR)** - Tinh chỉnh tương phản phong cách đơn ngôn ngữ (Của FontDiffuser gốc).

- **CL: Cross-Lingual Style Contrastive Refinement (CL-SCR)** - Tinh chỉnh tương phản phong cách đa ngôn ngữ (Đè xuất cải tiến).

Kết quả thực nghiệm trên hai hướng chuyển đổi được trình bày chi tiết tại [Bảng 4.6](#) và [Bảng 4.7](#).

Bảng 4.6 — Phân tích ảnh hưởng của các thành phần M, R, S và CL đối với hiệu năng mô hình trên tác vụ Latin → Hán tự.

	Mô-đun				L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
	M	R	S	CL				
Ours _{AZ}	x	x	x	x	0.2441	0.2983	0.4434	70.3650
	✓	✓	✓	x	<u>0.1976</u>	<u>0.3775</u>	<u>0.2968</u>	<u>14.6871</u>
	✓	✓	x	✓	0.1939	0.3890	0.2911	11.7691
UFSC	x	x	x	x	0.2815	0.1965	0.4854	75.7399
	✓	✓	✓	x	<u>0.2283</u>	<u>0.2946</u>	<u>0.3184</u>	<u>29.0999</u>
	✓	✓	x	✓	0.2214	0.3197	0.2954	13.5508

Bảng 4.7 — Phân tích ảnh hưởng của các thành phần M, R, S và CL đối với hiệu năng mô hình trên tác vụ Hán tự → Latin.

	Mô-đun				L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
	M	R	S	CL				
Ours _{All}	x	x	x	x	0.2763	0.2491	0.4792	84.7434
	✓	✓	✓	x	<u>0.1223</u>	<u>0.6107</u>	<u>0.2270</u>	<u>21.2234</u>
	✓	✓	x	✓	0.1083	0.6406	0.2019	14.7298
UFSC	x	x	x	x	0.3017	0.1793	0.5102	119.9425
	✓	✓	✓	x	<u>0.1370</u>	<u>0.5731</u>	<u>0.2476</u>	<u>59.5788</u>
	✓	✓	x	✓	0.1090	0.6377	0.1985	41.1152

Nhận xét và Thảo luận:

Quan sát từ dữ liệu thực nghiệm cho thấy vai trò nền tảng không thể thay thế của các mô-đun **M** và **R**. Khi tích hợp hai mô-đun này vào mạng Baseline, hiệu năng mô hình có sự chuyển biến mang tính bước ngoặt, thể hiện qua việc **chỉ số FID giảm sâu** ở cả hai hướng nghiên cứu. Đơn cử như trong kịch bản e2c (UFSC), việc có M và R giúp FID giảm từ **70.36** xuống **29.10** (tương ứng với cấu hình FontDiffuser Gốc). Điều này khẳng định rằng mạng Diffusion thuận túy gặp rất nhiều khó khăn trong việc định hình cấu trúc ký tự phức tạp nếu chỉ dựa vào đặc trưng cấp cao; M và R chính là “bộ khung xương” cung cấp các đặc trưng nội dung chi tiết đa tầng và tinh chỉnh độ khớp không gian, giúp mô hình dựng hình chính xác các nét và bộ thủ.

Tuy nhiên, điểm nhấn quan trọng nhất nằm ở sự so sánh giữa mô-đun **S (SCR gốc)** và **CL (CL-SCR đề xuất)**. Kết quả thực nghiệm cho thấy **CL-SCR** vượt trội hơn hẳn so với SCR gốc, đặc biệt là trong các kịch bản khó (**Unseen Font**). Cụ thể, trong hướng **e2c** (UFSC), việc thay thế S bằng CL giúp FID giảm mạnh từ **29.10** xuống **13.55**. Tương tự ở hướng **c2e** (UFSC), FID giảm từ **59.58** xuống **41.11**.

Lý giải: **SCR gốc** vốn được thiết kế cho bài toán đơn ngôn ngữ, nơi khoảng cách giữa các phong cách nhỏ hơn. Khi áp dụng cho bài toán đa ngôn ngữ (**Cross-lingual**), SCR gốc gặp khó khăn trong việc tách biệt triệt để phong cách khỏi nội dung do sự khác biệt lớn về hình thái học. Ngược lại, **CL-SCR** với **cơ chế tương phản đa miền và chiến lược lấy mẫu âm cải tiến** đã giúp mô hình “hiểu” và trích xuất được bản chất phong cách (như kết cấu, bút pháp) một cách trừu tượng hơn, qua đó đảm bảo chất lượng sinh ảnh ổn định và tự nhiên ngay cả với các font chữ mới lạ.

Bảng 4.8 — So sánh kết quả sinh ảnh định tính giữa các mô-đun khác nhau khác nhau trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (**e2c** và **c2e**).

	Mô-đун M R S CL	Example 1	Example 2
UFSC (e2c)	x x x x	ニ 口 ァ	口 C 〇
	x x ✓ x	默 首 音	默 首 音
	x x x ✓	默 首 音	默 首 音

	Target	默首音	默首音
		Example 1	Example 2
UFSC (c2e)	x x x x	奎雷田	赤奏弦
	x x ✓ x	t d k	t d k
	x x x ✓	t d k	t d k
	Target	t d k	t d k

Kết luận: Tổng hợp lại, kết quả nghiên cứu bóc tách đã làm sáng tỏ vai trò riêng biệt và bổ trợ lẫn nhau của các thành phần kiến trúc. Trong khi **MCA** và **RSI** đóng vai trò là nền tảng cấu trúc không thể thiếu để ngăn chặn sự sụp đổ hình dáng ký tự, thì **CL-SCR** chính là nhân tố quyết định nâng tầm chất lượng thị giác và khả năng tổng quát hoá. Việc CL-SCR giúp giảm sâu chỉ số **FID** trên các **tập dữ liệu lạ (UFSC)** so với SCR gốc khẳng định rằng cơ chế tương phản đa ngôn ngữ là chìa khoá để mô hình vượt qua rào cản hình thái học, cho phép chuyển giao phong cách Latin sang Hán tự một cách tự nhiên và linh hoạt hơn.

4.5.2. Ảnh hưởng của Tăng cường dữ liệu (Data Augmentation)

Mục tiêu của nghiên cứu này là đánh giá vai trò của **chiến lược tăng cường dữ liệu**, cụ thể là kỹ thuật **Random Resized Crop** (cắt và thay đổi tỷ lệ ngẫu nhiên) được áp dụng trong quá trình huấn luyện mô-đun **CL-SCR**. Về mặt lý thuyết, việc tăng cường dữ liệu giúp mô hình học được **các đặc trưng phong cách bất biến theo tỷ lệ** và tránh hiện tượng **quá khớp (overfitting)**. Để kiểm chứng điều này, khoa luận **so sánh hiệu năng** của mô hình tiêu biểu ($Ours_{AZ}$ cho hướng e2c và $Ours_{All}$ cho hướng c2e) trong hai cấu hình: **có và không có Augmentation**.

Kết quả thực nghiệm được trình bày chi tiết tại [Bảng 4.9](#) và [Bảng 4.10](#).

Bảng 4.9 — Phân tích ảnh hưởng của tăng cường dữ liệu đối với hiệu năng mô hình trên tác vụ Latin → Hán tự (e2c).

	Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
SFUC	Ours _{AZ} (w/o Augment)	<u>0.1974</u>	<u>0.3831</u>	<u>0.2967</u>	<u>14.1295</u>
	Ours _{AZ} (w/ Augment)	0.1939	0.3890	0.2911	11.7691
UFSC	Ours _{AZ} (w/o Augment)	<u>0.2295</u>	<u>0.3066</u>	<u>0.3060</u>	<u>15.7706</u>
	Ours _{AZ} (w/ Augment)	0.2214	0.3197	0.2954	13.5508

Bảng 4.10 — Phân tích ảnh hưởng của tăng cường dữ liệu đối với hiệu năng mô hình trên tác vụ Hán tự → Latin (c2e).

	Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
SFUC	Ours _{All} (w/o Augment)	0.1076	0.6504	0.1978	12.3668
	Ours _{All} (w/ Augment)	<u>0.1083</u>	<u>0.6406</u>	<u>0.2019</u>	<u>14.7298</u>
UFSC	Ours _{All} (w/o Augment)	<u>0.1126</u>	<u>0.6364</u>	<u>0.2015</u>	<u>43.0665</u>
	Ours _{All} (w/ Augment)	0.1090	0.6377	0.1985	41.1152

Nhận xét và Thảo luận:

Đối với hướng chuyển đổi từ Latin sang Hán tự (e2c), quan sát tại [Bảng 4.9](#) cho thấy việc áp dụng Augmentation mang lại sự cải thiện **toàn diện và nhất quán** trên mọi chỉ số ở cả hai kịch bản SFUC và UFSC. **Đáng chú ý nhất là chỉ số FID trên tập UFSC giảm mạnh từ 15.77 xuống 13.55**, tương ứng với mức cải thiện **khoảng 14%**. Điều này có thể được lý giải bởi **đặc thù cấu trúc đơn giản** của ký tự Latin đóng vai trò là ảnh phong cách. Nếu thiếu đi sự đa dạng hóa dữ liệu thông qua Augmentation, mô hình dễ bị phụ thuộc vào các đặc trưng vị trí không gian cố định. Kỹ thuật **Random Resized Crop** buộc mô-đun CL-SCR phải tập trung học các **đặc trưng bản chất** như độ dày nét, serif hay độ tương phản bất kể biến đổi về kích thước hay vị trí, từ đó giúp quá trình áp dụng phong cách lên cấu trúc phức tạp của Hán tự trở nên linh hoạt và tự nhiên hơn.

Trong khi đó, hướng chuyển đổi ngược lại từ Hán tự sang Latin (c2e) tại [Bảng 4.10](#) lại hé lộ một sự đánh đổi thú vị giữa khả năng **ghi nhớ và khai quát hoá**.

Trên tập dữ liệu đã biết (SFUC), câu hình không có Augmentation đạt kết quả tốt hơn với FID 12.36 so với 14.72. Tuy nhiên, ưu thế **đảo chiều hoàn toàn** trên tập dữ liệu chưa biết (UFSC), nơi câu hình có Augmentation giành lại vị thế dẫn đầu với FID giảm từ **43.06** xuống **41.11** và sai số L1 cũng được cải thiện. Hiện tượng này minh chứng rõ ràng cho vai trò **điều hòa (Regularization)** của tăng cường dữ liệu. Ở kịch bản SFUC, việc thiếu nhiễu cho phép mô hình **tối ưu hóa cục bộ (overfit)** trên các mẫu đã thấy, dẫn đến chỉ số cao nhưng kém bền vững. Ngược lại, khi đối mặt với dữ liệu lạ trong UFSC, khả năng ghi nhớ trở nên vô hiệu, và lúc này các **đặc trưng phong cách cốt lõi** mang tính khái quát cao mà mô hình học được nhờ **Augmentation** mới thực sự phát huy tác dụng. Vì vậy, kết quả vượt trội trên UFSC khẳng định rằng tăng cường dữ liệu là thành phần thiết yếu để đảm bảo **khả năng tổng quát hóa** của mô hình trong các ứng dụng thực tế.

Bảng 4.11 — So sánh kết quả sinh ảnh định tính giữa mô hình có và không có áp dụng Tăng cường dữ liệu trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (e2c và c2e).

		Example 1	Example 2
UFSC (e2c)	w/ Augment		
	w/o Augment		
	Target		
UFSC (c2e)		Example 1	Example 2
	w/ Augment		
	w/o Augment		
	Target		

Kết luận: Dựa trên phân tích trên, khoá luận khẳng định **chiến lược Tăng cường dữ liệu** là thành phần không thể thiếu, đặc biệt quan trọng để nâng cao hiệu suất trên

các dữ liệu chưa từng biết (Unseen Domains), mặc dù có thể đánh đổi một lượng nhỏ hiệu năng trên các dữ liệu đã biết.

4.5.3. Ảnh hưởng của Chế độ hàm loss

Trong kiến trúc CL-SCR, hàm mất mát InfoNCE[24] đóng vai trò điều hướng không gian biểu diễn phong cách. khoá luận khảo sát **ba biến thể chiến lược huấn luyện** được định nghĩa trong tham số `loss_mode` :

- `scr_intra` : Chỉ sử dụng mẫu âm nội miền (Intra-domain). Ví dụ: so sánh Style Latin với các Style Latin khác.
- `scr_cross` : Chỉ sử dụng mẫu âm xuyên miền (Cross-domain). Ví dụ: so sánh Style Latin với Style Hán tự.
- `scr_both` : Kết hợp cả hai với trọng số $\alpha_{\text{intra}} = 0.3$ và $\beta_{\text{cross}} = 0.7$.

Kết quả thực nghiệm được trình bày tại [Bảng 4.12](#) và [Bảng 4.13](#).

Bảng 4.12 — Phân tích ảnh hưởng của các chế độ loss đối với hiệu năng mô hình trên tác vụ Latin → Hán tự (e2c).

	Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
SFUC	Ours _{AZ} (scr_intra)	<u>0.1969</u>	<u>0.3812</u>	<u>0.2958</u>	11.9552
	Ours _{AZ} (scr_cross)	0.1993	0.3770	0.2982	<u>11.8645</u>
	Ours _{AZ} (scr_both)	0.1939	0.3890	0.2911	11.7691
UFSC	Ours _{AZ} (scr_intra)	<u>0.2290</u>	<u>0.3008</u>	<u>0.3085</u>	<u>15.7197</u>
	Ours _{AZ} (scr_cross)	0.2326	0.2911	0.3128	16.2615
	Ours _{AZ} (scr_both)	0.2214	0.3197	0.2954	13.5508

Bảng 4.13 — Phân tích ảnh hưởng của các chế độ loss đối với hiệu năng mô hình trên tác vụ Hán tự → Latin (c2e).

	Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
SFUC	Ours _{All} (scr_intra)	0.0993	0.6614	0.1903	13.6449
	Ours _{All} (scr_cross)	0.1091	<u>0.6436</u>	<u>0.2017</u>	<u>14.0159</u>



	Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
UFSC	Ours _{All} (scr_both)	<u>0.1083</u>	0.6406	0.2019	14.7298
	Ours _{All} (scr_intra)	0.0971	0.6601	0.1845	<u>41.3399</u>
	Ours _{All} (scr_cross)	0.1175	0.6209	0.2095	44.7758
	Ours _{All} (scr_both)	<u>0.1090</u>	<u>0.6377</u>	<u>0.1985</u>	41.1152

Nhận xét và Thảo luận:

Đối với hướng chuyển đổi từ Latin sang Hán tự (e2c), số liệu tại [Bảng 4.12](#) phản ánh **sự thống trị rõ rệt của chiến lược hỗn hợp scr_both** trên hầu hết các chỉ số, đặc biệt là sự cải thiện vượt bậc về chỉ số FID trong kịch bản khó UFSC (đạt **13.55** so với 15.72 của scr_intra và 16.26 của scr_cross). Kết quả này có thể được lý giải bởi **đặc thù thông tin “thưa” (sparse)** của phong cách Latin. Nếu chỉ sử dụng so sánh nội miên scr_intra , mô hình khó học được cách các đặc trưng Latin đơn giản tương tác với cấu trúc Hán tự phức tạp; ngược lại, nếu chỉ dùng scr_cross , khoảng cách miền quá lớn lại gây ra sự bất ổn định trong quá trình hội tụ. Do đó, sự kết hợp trong scr_both **đóng vai trò như cầu nối**, giúp mô hình vừa nắm bắt vững chắc đặc trưng nội tại của Latin, vừa học được mối tương quan ngữ nghĩa với Hán tự để tạo ra kết quả tối ưu.

Bức tranh trở nên phức tạp và thú vị hơn khi xét đến chiều ngược lại từ Hán tự sang Latin (c2e) tại [Bảng 4.13](#), nơi xuất hiện một nghịch lý về **độ giàu thông tin**. Khác với hướng e2c , chiến lược scr_intra **lại thể hiện sự vượt trội về các chỉ số cấu trúc và điểm ảnh**(L1 thấp nhất 0.097, SSIM cao nhất) trên cả hai tập dữ liệu. Nguyên nhân sâu xa nằm ở bản chất “**đậm đặc**” (dense) **và giàu thông tin** của phong cách Hán tự (nét bút, độ dày, kết cấu). Chỉ cần **so sánh nội bộ giữa các Hán tự** là đã đủ để mô hình trích xuất được một vector phong cách mạnh mẽ. Trong bối cảnh này, việc ép buộc so sánh xuyên miền với Latin (through qua thành phần cross trong scr_both) vô tình tạo ra nhiều do sự khác biệt quá lớn về cấu trúc, làm giảm nhẹ độ chính xác tái tạo. Tuy nhiên, scr_both **vẫn giữ được ưu thế về độ tự nhiên tổng thể** (FID 41.11 so với 41.34) trên tập lạ UFSC, đóng vai trò như một cơ chế điều hòa cần thiết để đảm bảo tính thẩm mỹ khi đối mặt với các font hoàn toàn mới.

Bảng 4.14 — So sánh kết quả sinh ảnh định tính giữa các chế độ mât mát khác nhau trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (e2c và c2e).

		Example 1	Example 2
UFSC (e2c)	scr_intra		
	scr_cross		
	scr_both		
	Target		
		Example 1	Example 2
UFSC (c2e)	scr_intra		
	scr_cross		
	scr_both		
	Target		

Kết luận: Tổng kết lại, đối với bài toán tổng quát, **chiến lược scr_both là lựa chọn an toàn và ổn định nhất** để cân bằng giữa độ chính xác và tính tự nhiên. Tuy nhiên, thực nghiệm cũng mở ra một góc nhìn quan trọng: khi miền nguồn có lượng thông tin phong phú như Hán tự, **chiến lược học nội miền (scr_intra) cũng mang lại hiệu quả rất ấn tượng**, gợi ý tiềm năng tối ưu hoá chi phí huấn luyện cho các ứng dụng cụ thể mà không nhất thiết phải phụ thuộc vào dữ liệu cặp đôi xuyên ngôn ngữ.

4.5.4. Ảnh hưởng của số lượng mẫu âm

Trong khuôn khổ của **phương pháp học tương phản (Contrastive Learning)**, **số lượng mẫu âm (K)** đóng vai trò quan trọng trong việc định hình không gian biểu diễn đặc trưng. Theo lý thuyết thông thường, việc tăng số lượng mẫu âm thường giúp

mô hình phân biệt tốt hơn giữa các đặc trưng phong cách, từ đó học được các biểu diễn phong phú hơn. Để kiểm chứng giả thuyết này trong bối cảnh sinh phông chữ đa ngôn ngữ, khoá luận tiến hành thực nghiệm với các giá trị **K lần lượt là 4, 8 và 16** trên cả hai hướng chuyển đổi. Kết quả chi tiết được tổng hợp tại [Bảng 4.15](#) và [Bảng 4.16](#).

Bảng 4.15 — Phân tích ảnh hưởng của số lượng mẫu âm đối với hiệu năng mô hình trên tác vụ Latin → Hán tự (e2c).

	Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
SFUC	Ours _{AZ} (num_neg = 4)	0.1939	0.3890	0.2911	<u>11.7691</u>
	Ours _{AZ} (num_neg = 8)	0.1972	<u>0.3835</u>	<u>0.2952</u>	12.3750
	Ours _{AZ} (num_neg = 16)	<u>0.1967</u>	0.3833	0.2956	10.6901
UFSC	Ours _{AZ} (num_neg = 4)	0.2214	0.3197	0.2954	13.5508
	Ours _{AZ} (num_neg = 8)	0.2285	0.3048	0.3061	<u>15.0245</u>
	Ours _{AZ} (num_neg = 16)	<u>0.2273</u>	<u>0.3064</u>	<u>0.3048</u>	16.7855

Bảng 4.16 — Phân tích ảnh hưởng của số lượng mẫu âm đối với hiệu năng mô hình trên tác vụ Hán tự → Latin (c2e).

	Phương pháp	L1 ↓	SSIM ↑	LPIPS ↓	FID ↓
SFUC	Ours _{All} (num_neg = 4)	0.1083	0.6406	0.2019	14.7298
	Ours _{All} (num_neg = 8)	<u>0.1080</u>	<u>0.6464</u>	<u>0.1999</u>	<u>14.8365</u>
	Ours _{All} (num_neg = 16)	0.1059	0.6468	0.1992	15.7326
UFSC	Ours _{All} (num_neg = 4)	<u>0.1090</u>	<u>0.6377</u>	0.1985	41.1152
	Ours _{All} (num_neg = 8)	0.1087	0.6398	0.1985	43.8077
	Ours _{All} (num_neg = 16)	0.1111	0.6311	<u>0.2008</u>	<u>43.5042</u>

Nhận xét và Thảo luận:

Phân tích số liệu từ thực nghiệm cho thấy một kết quả **trái ngược với trực giác phổ biến trong học tương phản** trên các tác vụ thị giác máy tính khác. Cụ thể, trong

hướng chuyên đổi từ Latin sang Hán tự ([Bảng 4.15](#)), cấu hình sử dụng số lượng mẫu âm nhỏ nhất ($K = 4$) lại thể hiện sự vượt trội về **độ ổn định và khả năng tổng quát hoá**. Trên tập kiểm thử khó UFSC, cấu hình này đạt chỉ số FID tốt nhất là **13.55**, thấp hơn đáng kể so với mức 16.78 khi sử dụng 16 mẫu âm. Đồng thời, các chỉ số về cấu trúc như SSIM và sai số L1 cũng đạt giá trị tối ưu tại $K = 4$. Điều này gợi ý rằng đối với hệ chữ Latin vốn có cấu trúc nét tương đối đơn giản và “thưa”, việc sử dụng quá nhiều mẫu âm có thể vô tình đưa vào các **tín hiệu nhiễu** hoặc các mẫu có phong cách quá tương đồng (**false negatives**), khiến mô hình bị rối loạn trong việc định vị biên giới phong cách, dẫn đến suy giảm hiệu năng trên dữ liệu chưa từng thấy.

Xu hướng tương tự cũng được quan sát thấy ở chiều ngược lại từ Hán tự sang Latin ([Bảng 4.16](#)), mặc dù có sự phân hoá nhẹ giữa khả năng ghi nhớ và khái quát hoá. Khi đánh giá trên tập font đã biết (SFUC), việc tăng số lượng mẫu âm lên 16 giúp cải thiện nhẹ các chỉ số điểm ảnh như L1 và SSIM, do mô hình tận dụng được nhiều dữ liệu so sánh hơn để khớp chi tiết các nét phức tạp của Hán tự. Tuy nhiên, lợi thế này **không duy trì được khi chuyển sang tập font lạ (UFSC)**. Tại đây, cấu hình $K = 4$ một lần nữa khẳng định tính hiệu quả với chỉ số FID thấp nhất (**41.11**), vượt qua cả cấu hình $K = 8$ và $K = 16$. Kết quả này cũng có nhận định rằng trong bài toán chuyển đổi đa ngôn ngữ với sự chênh lệch lớn về miền dữ liệu, một tập hợp mẫu âm **nhỏ nhưng tinh gọn** sẽ hiệu quả hơn việc cố gắng phân biệt với một lượng lớn mẫu âm có thể gây nhiễu. Do đó, việc lựa chọn $K = 4$ không chỉ giúp **tối ưu hoá tài nguyên tính toán** mà còn đảm bảo chất lượng sinh ảnh tốt nhất về mặt thị giác.

Bảng 4.17 — So sánh kết quả sinh ảnh định tính giữa các số lượng mẫu âm khác nhau trên tập dữ liệu chưa từng thấy cho cả hai hướng tác vụ (`e2c` và `c2e`).

		Example 1	Example 2
UFSC (<code>e2c</code>)	num_neg = 4	默首音	默首音
	num_neg = 8	默首音	默首音
	num_neg = 16	默首音	默首音
	Target	默首音	默首音

		Example 1	Example 2
UFSC (c2e)	num_neg = 4	t d k	t d k
	num_neg = 8	t □k	t d k
	num_neg = 16	t d E	t d k
	Target	t d k	t d k

Kết luận: Tổng kết lại, thực nghiệm về số lượng mẫu âm đã làm sáng tỏ một đặc điểm thú vị trong bài toán chuyển đổi phong cách xuyên ngôn ngữ: **sự tối giản lại mang lại hiệu quả tối ưu**. Trái với kỳ vọng rằng nhiều mẫu âm sẽ giúp học biểu diễn phong cách tốt hơn, kết quả cho thấy việc **giới hạn $K = 4$** giúp mô hình xây dựng được **không gian biểu diễn phong cách cô đọng**, tránh được hiện tượng quá khớp (overfitting) hoặc nhiễu loạn thông tin từ các mẫu âm dư thừa. Đặc biệt trên các tập dữ liệu chưa từng thấy (UFSC), cấu hình $K = 4$ luôn duy trì vị thế dẫn đầu về chỉ số FID ở cả hai hướng chuyển đổi, chứng minh đây là **thiết lập tối ưu** để cân bằng giữa độ chính xác tái tạo và khả năng tổng quát hoá, đồng thời **giảm tải đáng kể chi phí huấn luyện**.

Chương 5

Kết Luận và Hướng Phát Triển

5.1. Kết quả đạt được

Khóa luận đã hoàn thành mục tiêu xây dựng một khung giải pháp toàn diện cho bài toán sinh phông chữ đa ngôn ngữ (Cross-lingual Font Generation), tập trung vào cặp ngôn ngữ có sự chênh lệch hình thái lớn là Latin và Hán tự. Đóng góp quan trọng nhất về mặt lý thuyết là việc đề xuất và tích hợp thành công mô-đun **Cross-Lingual Style Contrastive Refinement (CL-SCR)** vào kiến trúc khuếch tán nền tảng. Khác với các phương pháp tiếp cận trước đây thường gặp khó khăn trong việc tách biệt phong cách khỏi nội dung khi miền dữ liệu thay đổi, CL-SCR đã chứng minh khả năng học được các **biểu diễn phong cách bất biến (invariant style representations)**. Cơ chế này cho phép mô hình vượt qua rào cản về “**Bất cân xứng mật độ thông tin**”, giải quyết hiệu quả cả hai bài toán: ngoại suy phong cách từ cấu trúc Latin đơn giản sang Hán tự phức tạp (**e2c**) và trừu tượng hóa phong cách từ Hán tự rậm rạp sang Latin (**c2e**) mà không làm vỡ cấu trúc ký tự.

Về mặt thực nghiệm, kết quả định lượng trên tập dữ liệu chuẩn đã khẳng định sự vượt trội của phương pháp đề xuất so với các mô hình State-of-the-Art thuộc dòng GAN (như **DG-Font**, **CF-Font**) và cả mô hình FontDiffuser nguyên bản. Cụ thể, chỉ số **FID** và **LPIPS** được cải thiện đáng kể trên các tập dữ liệu chưa từng thấy (UFSC), chứng tỏ khả năng tổng quát hóa mạnh mẽ của mô hình. Bên cạnh đó, kết quả khảo sát người dùng cũng cho thấy sản phẩm sinh ra từ phương pháp đề xuất đạt độ thẩm mỹ cao, với nét chữ sắc sảo và tự nhiên, khắc phục được các lỗi phổ biến như **mờ nhòe (blurring)** hay **biến dạng (artifacts)** thường thấy ở các mô hình đối chứng. Thành công của khóa luận không chỉ dừng lại ở việc cải thiện các chỉ số đo lường mà còn

mở ra hướng đi mới cho việc ứng dụng Generative AI vào lĩnh vực thiết kế đồ họa và tự động hóa quy trình sáng tạo phông chữ đa ngữ.

5.2. Các định hướng phát triển

Mặc dù đã đạt được những kết quả khả quan, nghiên cứu vẫn tồn tại một số hạn chế nhất định, mở ra các hướng phát triển tiềm năng trong tương lai.

Thứ nhất, mở rộng phạm vi ngôn ngữ. Hiện tại mô hình mới chỉ tập trung vào cặp Latin-Hán. Hướng nghiên cứu tiếp theo sẽ thử nghiệm khả năng chuyển đổi trên các hệ chữ viết đa dạng hơn như **Tiếng Việt (Chữ Nôm/Quốc ngữ hóa)**, **Tiếng Nhật (Kanji/Kana)** hay **Tiếng Ả Rập**. Điều này đòi hỏi mô hình phải thích ứng với các đặc trưng hình thái học mới như dấu thanh điệu (diacritics) hoặc tính liên kết nét (cursiveness) đặc thù.

Thứ hai, tối ưu hóa tài nguyên huấn luyện. Mô hình Diffusion hiện tại đòi hỏi chi phí tính toán lớn. Để khắc phục, khóa luận đề xuất áp dụng các kỹ thuật **tinh chỉnh hiệu quả tham số (Parameter-Efficient Fine-Tuning - PEFT)** như **LoRA**[20] hoặc **Adapter**[21]. Việc này sẽ cho phép huấn luyện mô hình trên các GPU phổ thông mà không làm suy giảm đáng kể chất lượng sinh ảnh.

Cuối cùng, về khả năng xử lý phong cách cực đoan, mô hình đôi khi gặp khó khăn với các phông chữ thư pháp biến dạng cao. Giải pháp tiềm năng là tích hợp các cơ chế **chú ý biến dạng (Deformable Attention)** mạnh mẽ hơn hoặc kết hợp với **biểu diễn vector (Vector Graphics)** để nắm bắt tốt hơn các đường cong phức tạp thay vì chỉ dựa vào ảnh raster thuần túy.

Tài liệu tham khảo

- [1] Goodfellow IJ, Pouget-Abadie J, Mirza M, Xu B, Warde-Farley D, Ozair S, và c.s. Generative Adversarial Nets. trong:. Advances in Neural Information Processing Systems (NeurIPS), 2014, tr 2672–80.
- [2] Sohl-Dickstein J, Weiss EA, Maheswaranathan N, Ganguli S. Deep Unsupervised Learning using Nonequilibrium Thermodynamics. trong:. Proceedings of the 32nd International Conference on Machine Learning (ICML), 2015, tr 2256–65.
- [3] Ho J, Jain A, Abbeel P. Denoising Diffusion Probabilistic Models. trong:. Advances in Neural Information Processing Systems (NeurIPS), 2020.
- [4] Yang Z, Peng D, Kong Y, Zhang Y, Yao C, Jin L. FontDiffuser: One-Shot Font Generation via Denoising Diffusion with Multi-Scale Content Aggregation and Style Contrastive Learning. trong:. AAAI Conference on Artificial Intelligence (AAAI), 2024, tr 6603–11. <https://doi.org/10.1609/AAAI.V38I7.28482>.
- [5] Xie Y, Chen X, Sun L, Lu Y. DG-Font: Deformable Generative Networks for Unsupervised Font Generation. trong:. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2021, tr 5130–40. <https://doi.org/10.1109/CVPR46437.2021.00509>.
- [6] Wang C, Zhou M, Ge T, Jiang Y, Bao H, Xu W. CF-Font: Content Fusion for Few-Shot Font Generation. trong:. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023, tr 1858–67. <https://doi.org/10.1109/CVPR52729.2023.00185>.
- [7] Park S, Chun S, Cha J, Lee B, Shim H. Few-Shot Font Generation with Localized Style Representations and Factorization. trong:. Proc. AAAI Conf. Artif. Intell. (AAAI), 2021, tr 2393–402. <https://doi.org/10.1609/AAAI.V35I3.16340>.
- [8] Park S, Chun S, Cha J, Lee B, Shim H. Multiple Heads are Better than One: Few-Shot Font Generation with Multiple Localized Experts. trong:. Proc. IEEE/

CVF Int. Conf. Comput. Vis. (ICCV), 2021, tr 13880–9. <https://doi.org/10.1109/ICCV48922.2021.01364>.

- [9] Tang L, Cai Y, Liu J, Hong Z, Gong M, Fan M, và c.s. Few-Shot Font Generation by Learning Fine-Grained Local Styles. trong:. Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2022, tr 7885–94. <https://doi.org/10.1109/CVPR52688.2022.00774>.
- [10] Kong Y, Luo C, Ma W, Zhu Q, Zhu S, Yuan NJ, và c.s. Look Closer to Supervise Better: One-Shot Font Generation via Component-Based Discriminator. trong:. Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), 2022, tr 13472–81. <https://doi.org/10.1109/CVPR52688.2022.01312>.
- [11] Isola P, Zhu J-Y, Zhou T, Efros AA. Image-to-Image Translation with Conditional Adversarial Networks. trong:. Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), 2017, tr 5967–76. <https://doi.org/10.1109/CVPR.2017.632>.
- [12] Liu M-Y, Breuel TM, Kautz J. Unsupervised Image-to-Image Translation Networks. trong:. Advances in Neural Information Processing Systems (NeurIPS), 2017, tr 700–8.
- [13] Zhu J-Y, Park T, Isola P, Efros AA. Unpaired Image-to-Image Translation Using Cycle-Consistent Adversarial Networks. trong:. Proc. IEEE Int. Conf. Comput. Vis. (ICCV), 2017, tr 2242–51. <https://doi.org/10.1109/ICCV.2017.244>.
- [14] Liu M-Y, Huang X, Mallya A, Karras T, Aila T, Lehtinen J, và c.s. Few-Shot Unsupervised Image-to-Image Translation. trong:. Proc. IEEE/CVF Int. Conf. Comput. Vis. (ICCV), 2019, tr 10550–9. <https://doi.org/10.1109/ICCV.2019.01065>.
- [15] Zhu A, Lu X, Bai X, Uchida S, Iwana BK, Xiong S. Few-Shot Text Style Transfer via Deep Feature Similarity. IEEE Transactions on Image Processing 2020;29:6932–46. <https://doi.org/10.1109/TIP.2020.2995062>.
- [16] Li C, Taniguchi Y, Lu M, Konomi S. Few-shot Font Style Transfer between Different Languages. trong:. IEEE Winter Conference on Applications of Computer Vision (WACV), 2021, tr 433–42. <https://doi.org/10.1109/WACV48630.2021.00048>.

- [17] Heusel M, Ramsauer H, Unterthiner T, Nessler B, Hochreiter S. GANs Trained by a Two Time-Scale Update Rule Converge to a Local Nash Equilibrium. trong:. Advances in Neural Information Processing Systems (NeurIPS), 2017, tr 6626–37.
- [18] Wang Z, Bovik AC, Sheikh HR, Simoncelli EP. Image Quality Assessment: From Error Visibility to Structural Similarity. IEEE Transactions on Image Processing 2004;13:600–12. <https://doi.org/10.1109/TIP.2003.819861>.
- [19] Zhang R, Isola P, Efros AA, Shechtman E, Wang O. The Unreasonable Effectiveness of Deep Features as a Perceptual Metric. trong:. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018, tr 586–95. <https://doi.org/10.1109/CVPR.2018.00068>.
- [20] Hu EJ, Shen Y, Wallis P, Allen-Zhu Z, Li Y, Wang S, và c.s. LoRA: Low-Rank Adaptation of Large Language Models. trong:. International Conference on Learning Representations (ICLR), 2022.
- [21] Houlsby N, Giurgiu A, Jastrzebski S, Morrone B, Laroussilhe Q de, Gesmundo A, và c.s. Parameter-Efficient Transfer Learning for NLP. trong:. Proceedings of the 36th International Conference on Machine Learning (ICML), 2019, tr 2790–9.
- [22] Mao X, Li Q, Xie H, Lau RYK, Wang Z, Smolley SP. Least Squares Generative Adversarial Networks. trong:. IEEE International Conference on Computer Vision (ICCV), 2017, tr 2813–21. <https://doi.org/10.1109/ICCV.2017.304>.
- [23] Gatys LA, Ecker AS, Bethge M. A Neural Algorithm of Artistic Style. arXiv preprint arXiv:150806576 2015.
- [24] Oord A van den, Li Y, Vinyals O. Representation Learning with Contrastive Predictive Coding. arXiv preprint arXiv:180703748 2018.
- [25] Chen X, Xie Y, Sun L, Lu Y. DGFont++: Robust Deformable Generative Networks for Unsupervised Font Generation. arXiv preprint arXiv:221214742 2022.
- [26] Park S, Chun S, Cha J, Lee B, Shim H. Multiple Heads are Better than One: Few-Shot Font Generation with Multiple Localized Experts. trong:. IEEE/

CVF International Conference on Computer Vision (ICCV), 2021, tr 13880–9.
<https://doi.org/10.1109/ICCV48922.2021.01364>.

Phụ lục